

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

CC3084 – Data Science
Sección 20
Semestre II de 2026

Proyecto 2

Análisis exploratorio del conjunto CGIAR Eyes on the Ground

Ernesto Ascencio
Hugo Barillas
Esteban Cárcamo
Diego López

9 de septiembre de 2026

1. Situación problemática

ACRE Africa utilizó fotografías enviadas desde teléfonos inteligentes para revisar reclamaciones de seguros agrícolas y estimar pérdidas. La competencia describió que esta revisión requirió tiempo y retrasó la liquidación de reclamaciones. Debido a que una proporción considerable de los reclamos se relacionó con sequía, se planteó automatizar la estimación de su magnitud mediante imágenes de cultivos (Zindi, 2023).

2. Problema científico

Se planteó identificar las características tabulares y visuales que limitaron la generalización entre temporadas al estimar la magnitud del daño por sequía. También se examinó qué preprocesamiento se justificó antes de una etapa posterior de modelado.

3. Objetivos

Objetivo general

Se planteó caracterizar el conjunto CGIAR Eyes on the Ground mediante análisis exploratorio para identificar factores que limitaron la generalización entre temporadas y para definir un preprocesamiento justificado.

Objetivos específicos

1. Se planteó describir la estructura y la calidad de las variables tabulares y visuales, incluidos faltantes, duplicados e inconsistencias entre daño y magnitud.
2. Se planteó comparar la distribución de variables clave entre temporadas y entre las particiones de entrenamiento y prueba.
3. Se planteó cuantificar la agrupación de fotografías por campo y su relación con el riesgo de fuga de información durante la partición de los datos.

4. Investigación previa

El proyecto Eyes on the Ground reunió imágenes georreferenciadas y con marcas temporales de campos de pequeños productores, junto con etiquetas de manejo, fenología, daños y estimaciones de rendimiento. La documentación indicó que las fotografías se capturaron mediante teléfonos inteligentes bajo un protocolo estandarizado de seguro basado en imágenes y que la recolección cubrió condados de Kenia (Waithaka et al., 2022). CGIAR informó que el proyecto recibió apoyo de Lacuna Fund y que ACRE Africa e IFPRI participaron en su desarrollo (CGIAR, 2021).

La evaluación visual de estrés hídrico requirió cautela. La FAO describió que el marchitamiento y el enrollamiento de las hojas se asociaron con estrés hídrico, aunque síntomas visuales similares también pudieron aparecer por otras causas. Por ello, el color y la textura de una fotografía se trataron como señales parciales y no como diagnóstico agronómico concluyente (FAO, s. f.).

5. Descripción de los datos

Origen, volumen y correspondencia

El proyecto descargó Train.csv, Test.csv y SampleSubmission.csv desde la API de Zindi. Las imágenes se obtuvieron desde la carpeta indicada en el repositorio y se organizaron en las particiones train y test. Este informe se elaboró a partir de las salidas conservadas de los tres cuadernos y de las figuras incluidas en el repositorio. No se descargaron datos ni se ejecutaron cuadernos durante su elaboración.

Tabla 1. Volumen y correspondencia por conjunto.

Conjunto	Registros	Columnas tras carga	Imágenes en disco	Correspondencia
Entrenamiento	26 068	17	26 068	0 registros sin imagen y 0 imágenes sin registro
Prueba	8 663	16	8 663	0 registros sin imagen y 0 imágenes sin registro
Total	34 731	No aplica	34 731	Correspondencia completa en ambas particiones

El conteo de entrenamiento quedó 38 registros por debajo del conteo oficial acumulado de 26 106. La diferencia se concentró en LR2020 con 1 registro, LR2021 con 34 registros y SR2021 con 3 registros. El cuaderno verificó correspondencia exacta entre el CSV distribuido

y las imágenes locales. Por tanto, la diferencia documentó una discrepancia entre el conjunto distribuido y el conteo de referencia, no una falta de correspondencia local.

Variables originales y derivadas

Tabla 2. Variables originales del conjunto.

Variable original	Tipo	Escala	Descripción
ID	texto	nominal	Identificador del registro
filename	texto	nominal	Nombre de la imagen
growth_stage	categorica	ordinal	Etapas S, V, F o M
damage	categorica	nominal	Tipo de daño
extent	entero	cuantitativa discreta	Magnitud de 0 a 100
season	categorica	ordinal	Temporada LR2020, SR2020, LR2021 o SR2021

Tabla 3. Catálogos de etapa y daño.

Código	Significado
S	Siembra
V	Vegetativa
F	Floración
M	Madurez
DR	Sequía
G	Crecimiento sano
WD	Maleza
DS, FD, ND, PS y WN	Enfermedad, inundación, deficiencia de nutrientes, plaga y viento

Se derivaron productor, campo, cultivo, sitio, tipo de captura, formato del nombre, banderas de copia y repetición, ruta relativa y disponibilidad de archivo. El formato codificado permitió separar productor, campo, cultivo, sitio y captura. El formato secuencial no distinguió campos, por lo que el identificador del productor se utilizó como aproximación al campo. Además, 2 712 registros presentaron formato desconocido y no aportaron campo ni tipo de captura. Esta limitación redujo la cobertura de cualquier análisis basado en campo o captura.

Atributos derivados de las imágenes

El cuaderno de imágenes describió 34 731 archivos sin errores de lectura. Se derivaron dimensiones, peso, formato, orientación, proporciones de color, brillo, contraste, saturación, exceso de verde, sobreexposición, subexposición, nitidez y huella perceptual. La miniaturización limitó el efecto directo de la resolución en las medidas fotométricas. Los metadatos EXIF de marca y modelo no se encontraron en las imágenes procesadas.

6. Limpieza y preprocesamiento

Se conservaron los registros y se añadieron indicadores de calidad. La decisión evitó imputar o eliminar información sin una justificación empírica. El conjunto de entrenamiento no presentó faltantes en las variables originales, identificadores duplicados ni valores fuera de los dominios establecidos. Los faltantes se concentraron en variables derivadas del nombre de archivo.

Tabla 4. Bitácora de limpieza y decisiones.

Verificación	Registros	Decisión aplicada
Formato de nombre desconocido	2 712	Se conservaron y se excluyeron de cruces dependientes del formato
Campo o productor no identificado	2 712	Se excluyeron de la aptitud para modelado
Cultivo o sitio no identificado	4 745	Se conservaron sin imputación
Magnitud fuera de dominio	0	No se requirió corrección
Identificador o archivo duplicado	0	No se eliminó ningún registro
Sequía con magnitud cero	6	Se conservaron como posible ruido de etiqueta
Magnitud positiva con daño distinto de sequía	0	No se observó incoherencia de este tipo

Los indicadores marcaron 23 356 registros de entrenamiento como aptos para modelado. La bandera no filtró automáticamente los análisis posteriores. Por ello, las poblaciones incluidas se identificaron en cada resultado. El criterio de aptitud tampoco resolvió la incertidumbre de tratar productor y campo como equivalentes en la convención secuencial.

7. Análisis exploratorio

Magnitud y diagnóstico de sequía

La magnitud presentó media de 7.0961, desviación estándar de 18.6132, mediana de 0 y rango de 0 a 100. El 82.70 % de los registros tuvo magnitud cero. El criterio intercuartílico marcó 4 510 valores positivos como atípicos porque el primer y el tercer cuartil fueron cero. Esa clasificación no se utilizó para depurar, dado que los valores positivos constituyeron el fenómeno de interés.




Figura 1. Distribución de la magnitud en entrenamiento. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

La magnitud positiva apareció exclusivamente en la categoría DR. Se registraron 4 516 observaciones de sequía, con media de 40.9610 y máximo de 100. Seis observaciones DR tuvieron magnitud cero. La relación observada separó el problema en dos partes, identificar sequía y estimar severidad dentro de los casos diagnosticados como sequía.

Tabla 5. Magnitud por tipo de daño.

Daño	Registros	Media de magnitud	Máximo
G	11 623	0.0000	0
DR	4 516	40.9610	100
WD	9 238	0.0000	0
Otros cinco tipos	691	0.0000	0

En prueba se identificaron 1 503 registros DR y 7 160 registros con daño distinto de DR. Si la regla observada en entrenamiento se mantuviera en prueba, esos 7 160 registros tendrían magnitud cero. La inferencia permaneció condicionada porque Test.csv no incluyó la magnitud real.

Severidad, etapas y tipo de captura

Dentro de los 4 516 registros DR, la media fue 40.9610 y la mediana 40. La severidad media cambió por temporada. SR2020 registró 53.5166, LR2020 43.1458, SR2021 37.0562 y LR2021 34.5011. Las diferencias describieron un desplazamiento de etiquetas entre temporadas dentro del subconjunto relevante.




Figura 2. Magnitud de sequía por temporada. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

La sequía se concentró en madurez. La proporción de DR fue 48.59 % en M, frente a 13.82 % en F, 4.05 % en V y 0.62 % en S. Este patrón indicó que la etapa se asoció con la visibilidad o la anotación del daño, sin demostrar una relación causal independiente.




Figura 3. Composición del tipo de daño por etapa. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

La captura de seguimiento representó 22 744 registros y la de reclamo 459. La media de magnitud fue 7.8311 en seguimiento y 13.5076 en reclamo. Sin embargo, el tipo de captura cambió por temporada y faltó en 2 712 registros. Por ello, las diferencias de severidad entre temporadas pudieron reflejar parcialmente cambios de composición.

Asociación, agrupación y partición

La V de Cramer más alta se observó entre daño y etapa, con 0.32. La asociación entre temporada y tipo de captura fue 0.23. El eta cuadrado indicó que daño explicó 0.6937 de la varianza de magnitud, etapa explicó 0.1991, temporada 0.0084 y tipo de captura 0.0027 en el conjunto completo. La estimación global de temporada ocultó las diferencias observadas dentro de DR.




Figura 4. Asociación entre variables categóricas mediante V de Cramer. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

Se identificaron 3 051 campos a partir de los nombres reconocidos. La mediana fue 6 fotografías por campo, el máximo fue 60 y el 91.15 % de los campos tuvo más de una fotografía. En una simulación aleatoria 80/20, 1 971 campos quedaron en ambos lados y el 87.92 % de los registros de validación perteneció a campos compartidos. El resultado mostró que una partición aleatoria no aisló los grupos derivados del campo.




Figura 5. Fotografías por campo con recorte en el percentil 99. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

Se observaron 2 414 campos y 212 productores comunes entre entrenamiento y prueba. El 80.65 % de los registros de entrenamiento y el 88.51 % de prueba pertenecieron a campos compartidos. Este solapamiento indicó riesgo de fuga si se utilizaron campos o señales visuales específicas como entradas de modelos. El análisis no midió desempeño de modelos, por lo que no demostró la magnitud de una posible inflación de métricas.

Las distancias de variación total entre entrenamiento y prueba fueron 0.0088 para temporada, 0.0008 para etapa y 0.0016 para daño. Estas similitudes describieron las tres distribuciones examinadas. No demostraron por sí mismas el procedimiento exacto con el que se construyó la partición oficial.

Propiedades técnicas y calidad visual

Las 34 731 fotografías tuvieron formato JPEG. El ancho medio fue 1 037.30 píxeles, el alto medio fue 724.20, la mediana de megapíxeles fue 0.3072 y solo 1.39 % fue vertical. La resolución varió entre temporadas. LR2020 y SR2020 se concentraron en 640×480. SR2021 combinó 7 063 imágenes de 320×240 con resoluciones de varios megapíxeles.




Figura 6. Megapíxeles por temporada. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

La banda menor de 0.5 megapíxeles incluyó 100 % de LR2020 y SR2020, 95.03 % de LR2021 y 60.89 % de SR2021. La banda mayor de 5 megapíxeles incluyó 37.63 % de SR2021. Esta diferencia documentó un cambio de distribución técnica. El origen del cambio no se identificó porque ninguna imagen procesada conservó marca ni modelo EXIF.

El promedio de brillo fue 111.7518, el de contraste 61.6752, el de nitidez 1 408.0521, el de saturación 0.4189 y el de exceso de verde 0.1412. Bajo el umbral establecido, 1.82 % se clasificó como desenfocada y 3.58 % como mal expuesta. La proporción desenfocada aumentó

hasta 3.67 % en SR2021. Los umbrales sirvieron como diagnóstico operativo y no como validación de calidad visual absoluta.




Figura 7. Distribución de la nitidez. Elaboración propia con las salidas conservadas del cuaderno correspondiente.



Figura 8. Diez fotografías con menor nitidez medida. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

Similitud visual y asociación con la magnitud

Se excluyó una huella degenerada antes de agrupar las restantes. Entre 34 730 imágenes se formaron 34 663 grupos visuales. Ciento dieciocho imágenes pertenecieron a 51 grupos con más de un miembro y el mayor grupo tuvo 8 imágenes. Veintiún grupos incluyeron ambas particiones y reunieron 55 imágenes. Estos grupos representaron similitud según una huella diferencial, no confirmación de duplicación. La inspección de mosaicos mostró escenas distintas dentro de algunos grupos, por lo que el resultado se interpretó como una señal de revisión y no como prueba concluyente de repetición.

Grupo visual 13068




Figura 9. Ejemplo de grupo visual mixto según la huella perceptual. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

El exceso de verde presentó la asociación monotónica más alta con la magnitud en entrenamiento, con correlación de Spearman de -0.2522 . El promedio descendió de 0.1526 en magnitud 0 a -0.0091 en magnitud 100. Las demás asociaciones fueron menores en valor absoluto. El resultado mostró una señal visual moderada y no justificó tratar un único atributo como estimador suficiente de severidad.




Figura 10. Exceso de verde por nivel de magnitud. Elaboración propia con las salidas conservadas del cuaderno correspondiente.

La comparación entre las tres primeras temporadas y SR2021 mostró el mayor estadístico de Kolmogorov y Smirnov en megapíxeles, con 0.5532. Saturación, exposición, contraste, exceso de verde y nitidez también difirieron. Entre entrenamiento y prueba, los estadísticos fueron menores de 0.014 para los atributos examinados. Estos resultados describieron diferencias marginales entre las dos particiones y diferencias mayores por temporada. La dependencia entre fotografías del mismo campo limitó la interpretación de valores p como evidencia de independencia estadística.

8. Hallazgos

1. La magnitud se concentró en cero y la magnitud positiva apareció únicamente en DR. La tarea de regresión quedó condicionada al diagnóstico de sequía.

2. La severidad dentro de DR cambió entre temporadas. SR2020 presentó una media de 53.5166 y LR2021 una media de 34.5011.

3. Los campos derivados de nombres de archivo se solaparon ampliamente entre particiones. La simulación aleatoria mostró que 87.92 % de la validación perteneció a campos compartidos.

4. SR2021 presentó una mezcla de resoluciones y mayor proporción de imágenes desenfocadas. La evidencia describió desplazamiento técnico, aunque no identificó su causa.

5. El exceso de verde se relacionó inversamente con magnitud, con una asociación moderada. El atributo no explicó por sí solo la severidad.

6. Los registros originales cumplieron los dominios establecidos y no presentaron duplicados. Las limitaciones se concentraron en metadatos derivados y seis etiquetas DR con magnitud cero.

7. La similitud por huella perceptual afectó pocas imágenes en comparación con el solapamiento de campos. Su cálculo se consideró aproximado y susceptible a falsos positivos.

9. Conclusiones y siguientes pasos

El análisis delimitó una tarea condicional de estimación de severidad de sequía. Las etiquetas, la agrupación por campo y las condiciones técnicas de captura variaron de formas relevantes para el diseño de evaluación. La evidencia disponible no permitió atribuir causalidad a los cambios entre temporadas ni medir desempeño de modelos.

Se recomendó evaluar modelos mediante particiones que separaran campos y que, cuando fuera posible, separaran temporadas. Se recomendó restringir o reportar por separado el modelado de severidad para DR. Se recomendó normalizar tamaño y orientación de imagen antes de entrenar, aplicar aumentaciones coherentes con las variaciones observadas de resolución, exposición y nitidez, y comparar cualquier modelo con una línea base basada en exceso de verde. También se recomendó excluir nombres de archivo y variables derivadas como predictores directos, dado que codificaron grupos y procedimientos de captura que pudieron introducir fuga. Finalmente, se recomendó validar visualmente los grupos detectados por huella antes de tratarlos como duplicados.

10. Referencias

CGIAR. (2021, 19 de enero). ACRE Africa and IFPRI receive award from Lacuna Fund to develop unique agricultural datasets through smartphones. <https://www.cgiar.org/news-events/news/acre-africa-and-ifpri-receive-award-from-lacuna-fund-to-develop-unique-agricultural-datasets-through-smartphones>

Food and Agriculture Organization of the United Nations. (s. f.). Assessing and measuring your crop.
<https://www.fao.org/4/x8234e/x8234e06.htm>

Waithaka, L., Kramer, B., Hufkens, K., Kivuva, B., & Mansabdar, S. (2022). Eyes on the Ground
image data (Versión 1.0). Radiant MLHub. <https://doi.org/10.34911/rdnt.1bs2jw>

Zindi. (2023). CGIAR Eyes on the Ground Challenge.
<https://zindi.world/competitions/cgiar-eyes-on-the-ground-challenge>

Repositorio del proyecto. (s. f.). CC3084-Proyecto2.
<https://github.com/BARHUG0/CC3084-Proyecto2>