Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

CC3084 – Data Science
Sección 20
Semestre II de 2026

Estimación de daño por sequía en cultivos con aprendizaje automático

Informe final del proyecto CGIAR Eyes on the Ground

Ernesto Ascencio
Hugo Barillas
Esteban Cárcamo
Diego López

19 de octubre de 2026

Repositorio del proyecto
https://github.com/BARHUG0/CC3084-Proyecto2

Índice

1. Introducción
- Situación problemática
- Problema científico
- Contenido del informe

2. Objetivos
- Objetivo general
- Objetivos específicos

3. Marco teórico
- 3.1 Procesamiento de imágenes digitales
- 3.2 Análisis de imágenes desde el punto de vista agrícola
- 3.3 Algoritmos de aprendizaje automático para el problema

4. Metodología
- 4.1 Pasos seguidos
- 4.2 Selección de los conjuntos de entrenamiento y prueba
- 4.3 Selección de algoritmos
- 4.4 Medición del costo computacional
- 4.5 Recursos de cómputo
- 4.6 Lenguajes, herramientas y bibliotecas
- 4.7 Justificación de FastAPI y React

5. Resultados: datos, limpieza y análisis exploratorio
- 5.1 Características del conjunto original
- 5.2 Limpieza
- 5.3 Preprocesamiento
- 5.4 Análisis exploratorio
- 5.5 Implicaciones para el modelado

6. Resultados: ajuste y comparación de modelos
- 6.1 Protocolo de evaluación
- 6.2 Predictor constante
- 6.3 Regresión lineal sobre el exceso de verde
- 6.4 Random Forest
- 6.5 ResNet50
- 6.6 ResNet50 ajustada
- 6.7 DenseNet121
- 6.8 Comparación

7. Aplicación

8. Conclusiones

Referencias

1. Introducción

Situación problemática

ACRE Africa ofrece seguros agrícolas a pequeños productores de África oriental. Cuando un productor presenta un reclamo, la empresa lo resuelve con fotografías que el propio productor toma con su teléfono: un evaluador revisa cada imagen, identifica el tipo de daño y estima el porcentaje de pérdida. Esa revisión manual requiere tiempo y retrasa la liquidación de los reclamos. Como una proporción considerable de los reclamos se relaciona con sequía, el reto CGIAR Eyes on the Ground plantea automatizar la estimación de su magnitud a partir de las fotografías (Zindi, 2023).

El conjunto de datos proviene del proyecto Eyes on the Ground, que reunió fotografías de campos de pequeños productores en Kenia junto con etiquetas de etapa de crecimiento, tipo de daño y magnitud (Waithaka et al., 2022). ACRE Africa e IFPRI desarrollaron el proyecto con apoyo de Lacuna Fund (CGIAR, 2021).

El análisis exploratorio de la etapa anterior delimitó tres condiciones del problema:

- Solo el 17 % de las fotografías de entrenamiento tiene diagnóstico de sequía, y únicamente esas tienen una magnitud distinta de cero.
- Las fotografías se agrupan por campo. En una partición aleatoria, el 87.92 % de los registros de validación pertenecía a campos que también aparecían en el entrenamiento, lo que infla la evaluación.
- Las condiciones de captura cambian entre temporadas. En SR2021 la resolución media sube de 0.49 a 3.39 megapíxeles, y la nitidez y la saturación también se desplazan.

Problema científico

¿Con qué error se puede estimar la magnitud del daño por sequía a partir de una fotografía, cuando la evaluación separa los campos de entrenamiento y de prueba? ¿Qué tipo de modelo lo consigue con un costo compatible con una aplicación en línea: los que usan atributos visuales globales o las redes convolucionales preentrenadas?

Contenido del informe

- La sección 2 plantea los objetivos.
- La sección 3 resume el marco teórico sobre procesamiento de imágenes, análisis agrícola de fotografías y algoritmos útiles para el problema.
- La sección 4 describe la metodología: los pasos seguidos, la selección de los conjuntos, los algoritmos y las herramientas.
- La sección 5 presenta los datos, su limpieza y el análisis exploratorio.
- La sección 6 reporta el ajuste y la comparación de los modelos.
- La sección 7 describe la aplicación web.
- La sección 8 cierra con las conclusiones sobre cada objetivo.

2. Objetivos

Objetivo general

Estimar la magnitud del daño por sequía, en la escala de 0 a 100, a partir de fotografías de cultivos tomadas por pequeños productores. Para ello se comparan modelos basados en atributos visuales globales con redes convolucionales preentrenadas, y el resultado se pone a disposición en una aplicación web.

Objetivos específicos

1. **Obtención y preparación de los datos.** Construir un flujo reproducible de descarga, verificación, limpieza y extracción de atributos. El flujo produce un conjunto de modelado con una partición fija entre entrenamiento y prueba, en la que ningún campo aparece en ambos lados.
2. **Análisis de los datos.** Cuantificar la proporción de cada diagnóstico, la distribución de la magnitud y las diferencias en las condiciones de captura entre temporadas, para definir el alcance del modelado y de la evaluación.
3. **Construcción y comparación de modelos.** Entrenar un predictor constante de referencia, una regresión lineal sobre el exceso de verde, un Random Forest y dos redes convolucionales, DenseNet121 y ResNet50. Compararlos por MAE, RMSE y R^2 sobre las fotografías con sequía del conjunto de prueba.
4. **Ajuste de hiperparámetros.** Seleccionar los hiperparámetros de cada algoritmo con validación agrupada por campo, registrando el error de validación de cada configuración probada.
5. **Costo computacional.** Medir el tiempo de entrenamiento de cada modelo y su tiempo de inferencia por fotografía.
6. **Aplicación.** Desarrollar una API y una interfaz web que permitan consultar los datos, comparar los modelos y estimar la magnitud de una fotografía nueva.

3. Marco teórico

3.1 Procesamiento de imágenes digitales

Una fotografía digital en color es una matriz de píxeles con tres canales, rojo, verde y azul (RGB). En las fotografías del proyecto cada canal toma valores enteros de 0 a 255. Las operaciones de procesamiento transforman esa matriz para describirla, corregirla o prepararla como entrada de un modelo. Este proyecto usa dos familias de operaciones: la extracción de atributos globales y la preparación de la imagen completa para una red convolucional.

Atributos fotométricos. Resumen una imagen en pocos números interpretables. El brillo es la luminancia media y el contraste, su desviación estándar. La saturación mide la pureza del color en el espacio HSV, y las medias por canal describen el tono dominante. Las proporciones de píxeles sobreexpuestos o subexpuestos señalan problemas de iluminación.

Para la vegetación se usa el índice de exceso de verde, $ExG = 2g - r - b$, calculado sobre los canales normalizados por la suma $r + g + b$. Woebbecke et al. (1995) lo propusieron para separar plantas del suelo y de los residuos con imágenes de color. Su ventaja es que solo requiere una cámara RGB, a diferencia de índices como el NDVI, que necesitan una banda infrarroja (Cho et al., 2024).

Calidad de captura. La nitidez se estima con la varianza del laplaciano de la luminancia: una imagen enfocada tiene bordes marcados y, por tanto, una varianza alta. Los atributos que dependen de la escala, como la nitidez, se calculan sobre una miniatura de tamaño fijo. Sin esa normalización, reflejarían la resolución del archivo y no el contenido de la escena. Para detectar fotografías casi idénticas se usa una huella perceptual, un resumen binario de la imagen reducida. Dos huellas a pocos bits de distancia indican escenas muy parecidas.

Preparación para redes convolucionales. Las redes preentrenadas esperan una entrada de tamaño fijo y con la misma escala de valores que vieron al entrenarse. Por eso cada fotografía se redimensiona, se recorta al centro a 224 × 224 píxeles y se normaliza con la media y la desviación estándar de ImageNet. Durante el entrenamiento se aplican aumentos de datos: recortes aleatorios de escala y reflejos horizontales. Estos aumentos multiplican las vistas de cada fotografía sin cambiar su etiqueta y reducen el sobreajuste. En este problema no se alteran el tono ni la saturación, porque el color forma parte de la señal del daño.

3.2 Análisis de imágenes desde el punto de vista agrícola

El estrés hídrico se manifiesta en la planta con síntomas visibles: marchitamiento, enrollamiento de las hojas, amarillamiento y, en casos severos, secado de los tejidos. La FAO advierte que síntomas parecidos pueden deberse a otras causas, como enfermedades, deficiencias de nutrientes o la madurez del cultivo (Food and Agriculture Organization of the United Nations [FAO], s. f.). Una fotografía con hojas amarillas no permite atribuir por sí sola el daño a la sequía. Por eso el color se trata como una señal parcial y no como un diagnóstico.

Cho et al. (2024) organizan los métodos de evaluación del estrés hídrico según el sensor. Las cámaras térmicas miden la temperatura del dosel y las multiespectrales permiten calcular índices con bandas infrarrojas. Las cámaras RGB solo registran la apariencia visible. Las fotografías del proyecto son RGB y provienen de teléfonos inteligentes, así que los métodos fisiológicos de esa revisión no son reproducibles aquí.

El proyecto Eyes on the Ground recolectó fotografías de campos de pequeños productores en Kenia con teléfonos inteligentes. Su propósito fue apoyar un esquema de seguro agrícola basado en imágenes (Waithaka et al., 2022). En la competencia, la magnitud del daño es el porcentaje estimado de pérdida, en pasos de 10 de 0 a 100 (Zindi, 2023). Esta forma de captura introduce variaciones que no existen en estudios de laboratorio:

- **Encuadre y distancia:** cada fotografía muestra una porción distinta del campo, con cielo, suelo y vegetación en proporciones variables.
- **Iluminación:** la hora, las nubes y la dirección del sol cambian el color aparente de la planta.
- **Dispositivo:** la resolución y la calidad cambian entre teléfonos y entre temporadas.
- **Etapa fenológica:** un cultivo maduro se seca de forma natural y puede confundirse con daño por sequía.
- **Etiqueta:** la magnitud es una estimación visual de una persona, no una medición. Dos evaluadores pueden asignar valores distintos a la misma escena.

Estas condiciones explican por qué la literatura prefiere modelos que aprenden texturas y estructuras de la escena, en lugar de depender de un único índice de color.

3.3 Algoritmos de aprendizaje automático para el problema

Formulación como regresión

La magnitud es una variable numérica ordenada, por lo que el problema se plantea como regresión: el modelo devuelve un valor continuo entre 0 y 100. Las métricas adecuadas son el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). El MAE expresa el error típico en puntos de magnitud. El RMSE penaliza más los errores grandes. El R^2 compara el modelo con predecir siempre la media.

Modelos sobre atributos

Una estrategia clásica describe cada imagen con atributos de color, textura o forma y los usa como entradas de un modelo convencional. Cho et al. (2024) documentan el uso de máquinas de vectores de soporte, bosques aleatorios y redes neuronales con este enfoque. El bosque aleatorio combina muchos árboles de decisión, cada uno entrenado con una muestra distinta de los datos y de los atributos (Breiman, 2001). Promediar los árboles reduce la varianza de un árbol individual, y el método se aplica tanto a clasificación como a regresión. Su limitación en este problema es que los atributos globales pierden la estructura espacial: un promedio de color mezcla hojas, suelo y cielo.

Redes neuronales convolucionales

Una red convolucional aprende filtros que se deslizan sobre la imagen y detectan patrones locales. Las primeras capas responden a bordes y colores. Las capas profundas combinan esas respuestas en texturas, partes y objetos (LeCun et al., 2015). Al aprender la representación directamente de los píxeles, la red puede distinguir una hoja enrollada de una hoja sana con el mismo color medio.

Transferencia de aprendizaje

Entrenar una red profunda desde cero requiere cientos de miles de imágenes etiquetadas. La transferencia de aprendizaje parte de una red ya entrenada en un conjunto grande, normalmente ImageNet, con más de un millón de imágenes de mil categorías (Deng et al., 2009). Luego la adapta a la nueva tarea con pocos datos. Se puede reentrenar solo la capa de salida y conservar el resto como extractor de características, o ajustar también los últimos bloques. En agricultura es una práctica frecuente para reconocer enfermedades, malezas y estrés en plantas, porque los conjuntos etiquetados suelen ser pequeños (Kamilaris & Prenafeta-Boldú, 2018).

Mohanty et al. (2016) reconocieron 38 combinaciones de cultivo y enfermedad con una exactitud de 99.35 % dentro del conjunto PlantVillage. Sin embargo, en imágenes de otras fuentes la exactitud cayó a cerca de 31 %. El hallazgo muestra que un buen resultado en condiciones controladas no garantiza el desempeño en el campo. También muestra la importancia de evaluar con datos independientes: los autores agruparon las fotografías de una misma hoja para que no quedaran a ambos lados de la partición.

ResNet50

He et al. (2016) introdujeron las conexiones residuales. Cada bloque aprende una corrección que se suma a su propia entrada, de modo que el gradiente fluye sin degradarse aunque la red sea muy profunda. ResNet50 tiene 50 capas y alrededor de 25.6 millones de parámetros. Chandel et al. (2022) compararon cinco redes para identificar estrés hídrico en trigo con imágenes RGB y térmicas. Con imágenes RGB, ResNet50 obtuvo la mayor exactitud de validación, 96.9 %.

DenseNet121

Huang et al. (2017) propusieron la conectividad densa. Dentro de un bloque denso, cada capa recibe como entrada la concatenación de los mapas de características de todas las capas anteriores del bloque. Así, cada capa reutiliza lo que ya calcularon las demás y solo agrega unos pocos mapas nuevos, 32 por capa en DenseNet121. Entre bloques, unas capas de transición reducen el número de canales con convoluciones de 1×1 y la resolución con un promedio espacial.

DenseNet121 tiene cuatro bloques densos de 6, 12, 24 y 16 capas, y su salida es un vector de 1 024 características. Gracias a la reutilización, alcanza una exactitud comparable a ResNet50 en ImageNet con cerca de 8 millones de parámetros, menos de un tercio. Patra y Sahoo (2024) compararon cuatro redes preentrenadas para clasificar estrés hídrico en patata con imágenes RGB de dron, en condiciones de campo. DenseNet121 obtuvo la mayor exactitud de prueba, 90.75 %.

Adaptación a la estimación de severidad

Los estudios anteriores clasifican plantas como estresadas o sanas; ninguno estima una magnitud de 0 a 100 con fotografías como las del proyecto. Para adaptar las redes, se reemplaza la capa de clasificación por una neurona lineal que predice la magnitud dividida entre 100, y se entrena con el error cuadrático medio. La adaptación cambia la tarea aprendida, por lo que las exactitudes publicadas no son una expectativa del error de este proyecto.

La Tabla 3.1 resume la evidencia y su relación con el problema.

Tabla 3.1. Estudios consultados y su relación con el problema.

Estudio	Aporte principal	Límite para el proyecto
Cho et al. (2024)	Organiza sensores y familias de modelos para estrés hídrico.	Es una revisión; no ofrece experimentos con estos datos.
Chandel et al. (2021)	Compara AlexNet, GoogLeNet e Inception V3 en maíz, okra y soja.	Identifica estrés; no estima magnitud.
Chandel et al. (2022)	Compara cinco redes con imágenes RGB y térmicas de trigo.	Captura estandarizada y clasificación binaria.
Patra y Sahoo (2024)	Evalúa redes preentrenadas e interpretación visual en campo.	Clasifica regiones anotadas; no estima magnitud.
Mohanty et al. (2016)	Documenta la transferencia y la caída de desempeño externo.	Estudia enfermedades en hojas, no sequía en escenas completas.
Breiman (2001)	Fundamenta el bosque aleatorio y su uso en regresión.	No es evidencia experimental agrícola.

Con base en esta evidencia, el proyecto compara dos redes convolucionales preentrenadas, ResNet50 y DenseNet121, adaptadas a regresión. Como referencias se usan un bosque aleatorio y una regresión sobre el exceso de verde, que trabajan con atributos globales, y un predictor constante. Las referencias permiten medir cuánto aporta aprender la representación de la imagen frente a resumirla en pocos números.

4. Metodología

4.1 Pasos seguidos

1. **Adquisición.** Los CSV se descargan desde la API de Zindi con un token personal guardado en el almacén de credenciales del sistema. Las fotografías se descargan desde la carpeta compartida de la competencia en Google Drive. Una verificación confirma que cada registro tiene su fotografía y que no hay fotografías sin registro.
2. **Extracción de atributos.** Cada fotografía se describe con doce atributos globales: - exceso de verde ($2g - r - b$); - saturación, brillo y contraste; - medias de los canales rojo, verde y azul; - nitidez (varianza del laplaciano); - proporciones de píxeles sobreexpuestos y subexpuestos; - megapíxeles y relación de aspecto. Los diez primeros se calculan sobre una miniatura de 256 píxeles de lado; los dos últimos, sobre las dimensiones originales. El resultado se guarda en una caché reanudable.
3. **Limpieza.** Un registro es apto para modelado si cumple seis condiciones: su fotografía existe; no es una copia; la magnitud es un múltiplo de 10 entre 0 y 100; la etiqueta es coherente (solo los diagnósticos de sequía tienen magnitud positiva, y se descartan los de sequía con magnitud 0); y la temporada y el campo están identificados.
4. **Conjunto de modelado.** Los registros aptos de `Train.csv` cuyos atributos se calcularon sin error se unen en un único archivo, que fija la partición entre entrenamiento y prueba para todo el equipo.
5. **Modelado.** Cada integrante entrena sus modelos con las mismas reglas de partición, validación y evaluación, y guarda los resultados de prueba en un formato común.
6. **Comparación y aplicación.** Un cuaderno de comparación lee los resultados de todos los modelos. La API y la aplicación web los presentan y permiten estimar la magnitud de una fotografía nueva.

4.2 Selección de los conjuntos de entrenamiento y prueba

La partición separa campos y no fotografías, porque el análisis exploratorio mostró que una partición aleatoria deja casi toda la validación en campos ya vistos.

- **Prueba.** El 20 % de los campos se asigna a prueba con `GroupShuffleSplit` y semilla 42. El resto queda para entrenamiento. La prueba se usa una sola vez por modelo, después de fijar sus hiperparámetros.
- **Validación.** El ajuste de hiperparámetros usa cinco pliegues agrupados por campo (`GroupKFold`) dentro del entrenamiento. Las redes convolucionales usan el primero de esos pliegues para la parada temprana y la selección de configuración.
- **Alcance del modelado.** Los modelos se entrenan solo con los registros de sequía (DR), porque son los únicos con magnitud distinta de cero. Al evaluar, una regla fija asigna 0 a los registros con otro diagnóstico. Las métricas (MAE, RMSE y R^2 en la escala de 0 a 100) se reportan sobre los registros DR de prueba y sobre la prueba completa.
- **Generalización temporal.** Como experimento adicional, dentro del entrenamiento DR, el Random Forest se entrena con las temporadas anteriores a SR2021 y se evalúa en SR2021. Este experimento no usa la prueba.

4.3 Selección de algoritmos

Modelo	Familia	Entradas	Justificación
Predictor constante	Referencia	Ninguna	Predice la magnitud media del entrenamiento DR. Es el error mínimo que cualquier modelo debe superar.
Regresión lineal	Referencia	Exceso de verde	El exceso de verde es el atributo con mayor correlación con la magnitud (Spearman cercano a −0.25), y el análisis exploratorio recomendó usarlo como línea base.
Random Forest	Tabular	Nueve atributos globales	Capta relaciones no lineales e interacciones entre atributos, es robusto a escalas distintas y reporta la importancia de cada atributo.
DenseNet121 y ResNet50	Red convolucional	Fotografía RGB	Aprenden textura y contexto de la escena, que los atributos globales no capturan. Parten de pesos preentrenados en ImageNet.

El Random Forest usa nueve atributos: exceso de verde, saturación, brillo, contraste, las tres medias de canal y las dos proporciones de exposición. Excluye `megapixeles` y `nitidez` porque cambian con la temporada y pueden describir el teléfono más que el daño. El cuaderno 04 compara ambas variantes con la validación por campo.

Sus hiperparámetros se buscan con `RandomizedSearchCV`: 30 combinaciones, con la métrica `neg_root_mean_squared_error`, sobre este espacio:

- `n_estimators`: 100, 200, 300 y 500;
- `max_depth`: sin límite, 5, 10 y 20;
- `min_samples_leaf`: 1, 2, 5, 10, 20 y 50;
- `max_features`: raíz cuadrada, 0.5 y 1.0.

La combinación elegida se reajusta con todo el entrenamiento DR.

Las dos redes siguen el mismo procedimiento, para que la comparación entre ellas refleje la arquitectura y no la configuración:

Elemento	Valor
Entrada	224 × 224; para evaluar, `Resize(256)`, `CenterCrop(224)` y normalización de ImageNet
Aumentos	`RandomResizedCrop(224, scale=(0.7, 1.0))` y reflejo horizontal, sin alterar el tono
Objetivo y salida	Magnitud dividida entre 100, con una neurona lineal
Pérdida y optimizador	`MSELoss` y `AdamW` con `weight_decay=1e-4`
Lote y épocas	16, con precisión mixta; máximo 15 épocas y parada temprana de paciencia 3
Búsqueda	Tasa de aprendizaje de 1e-4 o 3e-4; se entrena la cabeza o también el último bloque

Además se entrenó una variante ajustada de ResNet50, descrita en la sección 6.6.

4.4 Medición del costo computacional

- **Tiempo de entrenamiento.** Incluye la búsqueda de hiperparámetros completa y el reajuste final.
- **Tiempo de inferencia.** Es el promedio por fotografía sobre los registros DR de prueba.
- En los modelos tabulares parte de los atributos ya calculados, así que no incluye su extracción.
- En las redes incluye la lectura de la fotografía.

Para que los tiempos sean comparables, los seis modelos finales se entrenaron y evaluaron en el mismo equipo.

4.5 Recursos de cómputo

Los seis modelos finales se entrenaron en una laptop con procesador Intel Core i9-13980HX (24 núcleos, 32 hilos), 16 GB de RAM y GPU NVIDIA GeForce RTX 4050 de 6 GB, con Linux (CachyOS), Python 3.14, PyTorch 2.14 y CUDA 13.0.

Modelos	Recurso	Uso
Predictor constante, regresión y Random Forest	CPU	La búsqueda del Random Forest valida las combinaciones en paralelo.
ResNet50, ResNet50 ajustada y DenseNet121	GPU mediante CUDA	Precisión mixta `bfloat16` y lectura de las fotografías con varios procesos en paralelo.

El desarrollo se repartió entre los equipos de los integrantes. La receta de la ResNet50 ajustada se diseñó en una MacBook Pro con chip M5 Pro, usando la GPU mediante Metal (`mps`), y los modelos tabulares se desarrollaron en una laptop con AMD Ryzen 7 8845HS. El código detecta el dispositivo disponible, por lo que los mismos cuadernos funcionan en CUDA, en Metal o solo en CPU.

4.6 Lenguajes, herramientas y bibliotecas

- **Análisis y modelado:** Python 3.11 o superior.
- pandas, NumPy, SciPy y PyArrow para los datos.
- Pillow para las imágenes.
- scikit-learn y joblib para los modelos tabulares.
- PyTorch y torchvision para las redes.
- Matplotlib para las figuras.
- JupyterLab para los cuadernos.
- pytest para las pruebas automáticas.
- **Datos:** requests y gdown para la descarga, y keyring para guardar el token fuera del código.
- **API:** FastAPI, Pydantic y Uvicorn.
- **Aplicación web:**
- TypeScript y React con Vite.
- Tailwind CSS y componentes de Radix para la interfaz.
- Recharts para los gráficos.
- TanStack Query para las consultas.
- openapi-typescript y openapi-fetch para el cliente tipado.
- **Informe y versiones:** Quarto para el informe, y Git con GitHub para el control de versiones.

4.7 Justificación de FastAPI y React

- **FastAPI.** Permite servir los modelos en el mismo lenguaje en que se entrenan, sin traducirlos a otro entorno. Sus esquemas de Pydantic validan cada petición y cada respuesta, y generan el contrato OpenAPI que comparten el backend y el frontend. Así, un cambio en el contrato se detecta en las pruebas antes de llegar a la interfaz. También maneja la carga de archivos que necesita la estimación de una fotografía nueva.
- **React.** Organiza la interfaz en componentes reutilizables entre las cinco páginas de la aplicación. Con TypeScript y los tipos generados desde el contrato OpenAPI, el frontend falla al compilar si usa un

campo que la API no ofrece. Su ecosistema aporta gráficos interactivos (Recharts) y manejo de consultas con caché (TanStack Query) sin desarrollarlos desde cero.

5. Resultados: datos, limpieza y análisis exploratorio

5.1 Características del conjunto original

Los datos provienen de la competencia CGIAR Eyes on the Ground, publicada en Zindi (2023). La tabla de registros (`Train.csv`, `Test.csv` y `SampleSubmission.csv`) se descargó desde la API de Zindi y las fotografías, desde la carpeta compartida indicada en el repositorio. Las imágenes se organizaron en las particiones `train` y `test`, y el cuaderno `01_adquisicion_datos.ipynb` verificó que cada registro tuviera su archivo y viceversa.

Tabla 5.1. Volumen y correspondencia por conjunto.

Conjunto	Registros	Imágenes en disco	Correspondencia
Entrenamiento	26 068	26 068	Sin registros huérfanos ni imágenes sin registro
Prueba	8 663	8 663	Sin registros huérfanos ni imágenes sin registro
Total	34 731	34 731	Correspondencia completa

El conteo de entrenamiento quedó 38 registros por debajo del conteo oficial de 26 106: falta 1 registro en LR2020, 34 en LR2021 y 3 en SR2021. Como la correspondencia entre la tabla y los archivos locales es exacta, la diferencia está en el conjunto distribuido y no en la descarga. La partición de prueba de Zindi no incluye la magnitud real, por lo que solo sirve para describir las imágenes y no para evaluar modelos.

Cada registro tiene seis variables originales:

Tabla 5.2. Variables originales del conjunto.

Variable	Tipo	Descripción
`ID`	Texto	Identificador del registro.
`filename`	Texto	Nombre del archivo de la fotografía.
`growth_stage`	Categórica ordinal	Etapa de crecimiento: siembra (S), vegetativa (V), floración (F) o madurez (M).
`damage`	Categórica nominal	Tipo de daño: sano (G), sequía (DR), enfermedad (DS), inundación (FD), deficiencia de nutrientes (ND), plaga (PS), maleza (WD) o viento (WN).
`extent`	Entera	Magnitud del daño, de 0 a 100 en pasos de 10. Es la variable objetivo.
`season`	Categórica ordinal	Temporada: LR2020, SR2020, LR2021 o SR2021.

Las variables se renombraron al español (`etapa`, `dano`, `magnitud` y `temporada`). Del nombre del archivo se derivaron el productor, el campo, el cultivo, el sitio y el tipo de captura: inicial, de seguimiento o de reclamo. El formato codificado del nombre permite separar todos esos elementos. En el formato secuencial no se distinguen campos, así que el productor se usa como aproximación del campo. En 2 712 registros el formato no se reconoce y no aporta campo ni tipo de captura.

5.2 Limpieza

La limpieza conservó los registros y agregó indicadores de calidad, en lugar de imputar o eliminar información sin una justificación empírica. El entrenamiento no tuvo faltantes en las variables originales, identificadores duplicados ni valores fuera de dominio. Los faltantes se concentraron en las variables derivadas del nombre de archivo.

Tabla 5.3. Bitácora de limpieza y decisiones.

Verificación	Registros	Decisión
Formato de nombre desconocido	2 712	Se conservaron y se excluyeron de los cruces que dependen del formato.
Campo o productor no identificado	2 712	Se excluyeron del modelado, porque no pueden asignarse a un grupo de la partición.
Cultivo o sitio no identificado	4 745	Se conservaron sin imputación.
Magnitud fuera de dominio	0	No se requirió corrección.
Identificador o archivo duplicado	0	No se eliminó ningún registro.
Sequía con magnitud cero	6	Se excluyeron del modelado como etiquetas incoherentes, porque una sequía diagnosticada debería tener magnitud positiva.
Magnitud positiva con daño distinto de sequía	0	No se observó esta incoherencia.

El indicador `apto_modelado` marca 23 350 registros de entrenamiento. Un registro es apto si su fotografía existe, no es una copia, su magnitud es válida, su etiqueta es coherente y su temporada y su campo están identificados. Las 34 731 fotografías se leyeron sin errores, y ninguna conservó los metadatos EXIF de marca y modelo del teléfono. Por eso el análisis se basa solo en los píxeles.

5.3 Preprocesamiento

Atributos de imagen. El módulo `src.caracteristicas` recorre las fotografías en paralelo y guarda los atributos en una caché de Parquet. Cada imagen se reduce a una miniatura de 256 píxeles por lado antes de calcular los atributos fotométricos. Se obtienen el exceso de verde, la saturación, el brillo, el contraste, las medias por canal, la nitidez, las proporciones de píxeles sobreexpuestos y subexpuestos, los megapíxeles, la relación de aspecto y la huella perceptual.

Conjunto de modelado. El módulo `src.conjunto` une los metadatos aptos para modelado con los atributos de imagen y produce un único archivo, `conjunto_modelado.parquet`, con 23 350 registros de 3 051 campos. De ellos, 4 489 tienen diagnóstico de sequía.

Partición por campo. Las fotografías de un mismo campo se parecen entre sí, así que separarlas al azar dejaría escenas casi iguales en el entrenamiento y en la prueba. Para evitarlo, la partición asigna campos completos: el 20 % de los campos va a la prueba con `GroupShuffleSplit` y una semilla fija (42). Todo el equipo obtiene la misma partición. Dentro del entrenamiento, la validación usa `GroupKFold` con cinco pliegues, también agrupados por campo.

Tabla 5.4. Partición del conjunto de modelado por campo.

Subconjunto	Registros	Registros DR	Campos
Entrenamiento	18 722	3 655	2 440
Prueba	4 628	834	611

Preparación para las redes. Las redes convolucionales reciben la fotografía completa. Las fotografías grandes se decodifican directamente a una escala reducida, sin bajar de 512 píxeles por lado, porque algunas de SR2021 superan los 10 megapíxeles y leerlas completas haría lento el entrenamiento. Después se redimensiona a 256 píxeles, se recorta al centro a 224 × 224 y se normaliza con las estadísticas de Image-

Net. La aplicación aplica la misma transformación a cada fotografía que recibe, sin que el usuario intervenga.

5.4 Análisis exploratorio

Magnitud y diagnóstico de sequía

La magnitud tiene media de 7.10, desviación estándar de 18.61 y mediana de 0. El 82.70 % de los registros de entrenamiento tiene magnitud cero. Con el criterio intercuartílico, los 4 510 valores positivos aparecerían como atípicos, porque el primer y el tercer cuartil valen cero. Esa marca no se usó para depurar: los valores positivos son precisamente el fenómeno de interés.

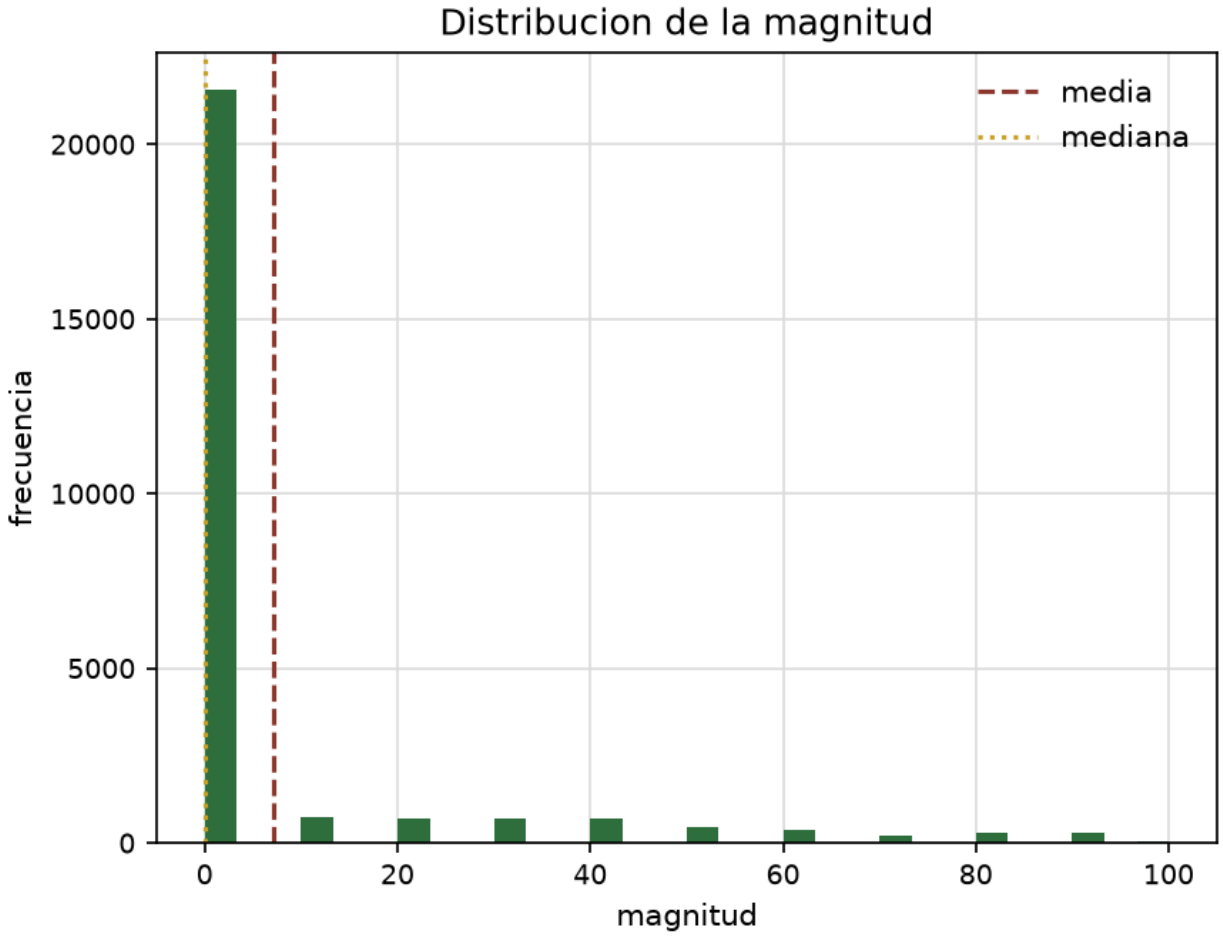


Figura 1. Distribución de la magnitud en el entrenamiento.

La magnitud positiva aparece solo en los registros con diagnóstico de sequía (DR). Los otros siete tipos de daño tienen siempre magnitud cero.

Tabla 5.5. Magnitud por tipo de daño en el entrenamiento.

Daño	Registros	Media de magnitud	Máximo
Sano (G)	11 623	0.00	0
Sequía (DR)	4 516	40.96	100
Maleza (WD)	9 238	0.00	0
Otros cinco tipos	691	0.00	0

Este hallazgo divide el problema en dos partes: reconocer la sequía y estimar su severidad. Como el diagnóstico está disponible en los datos y en la aplicación, los modelos estiman la severidad solo dentro de DR. A los demás diagnósticos se les asigna magnitud cero mediante una regla.

Severidad por temporada y etapa

Dentro de DR, la magnitud tiene media de 40.96 y mediana de 40, pero cambia entre temporadas. SR2020 registra una media de 53.52; LR2020, de 43.15; SR2021, de 37.06, y LR2021, de 34.50. Un modelo entrenado con una mezcla de temporadas debe estimar severidades que no se distribuyen igual en cada una.

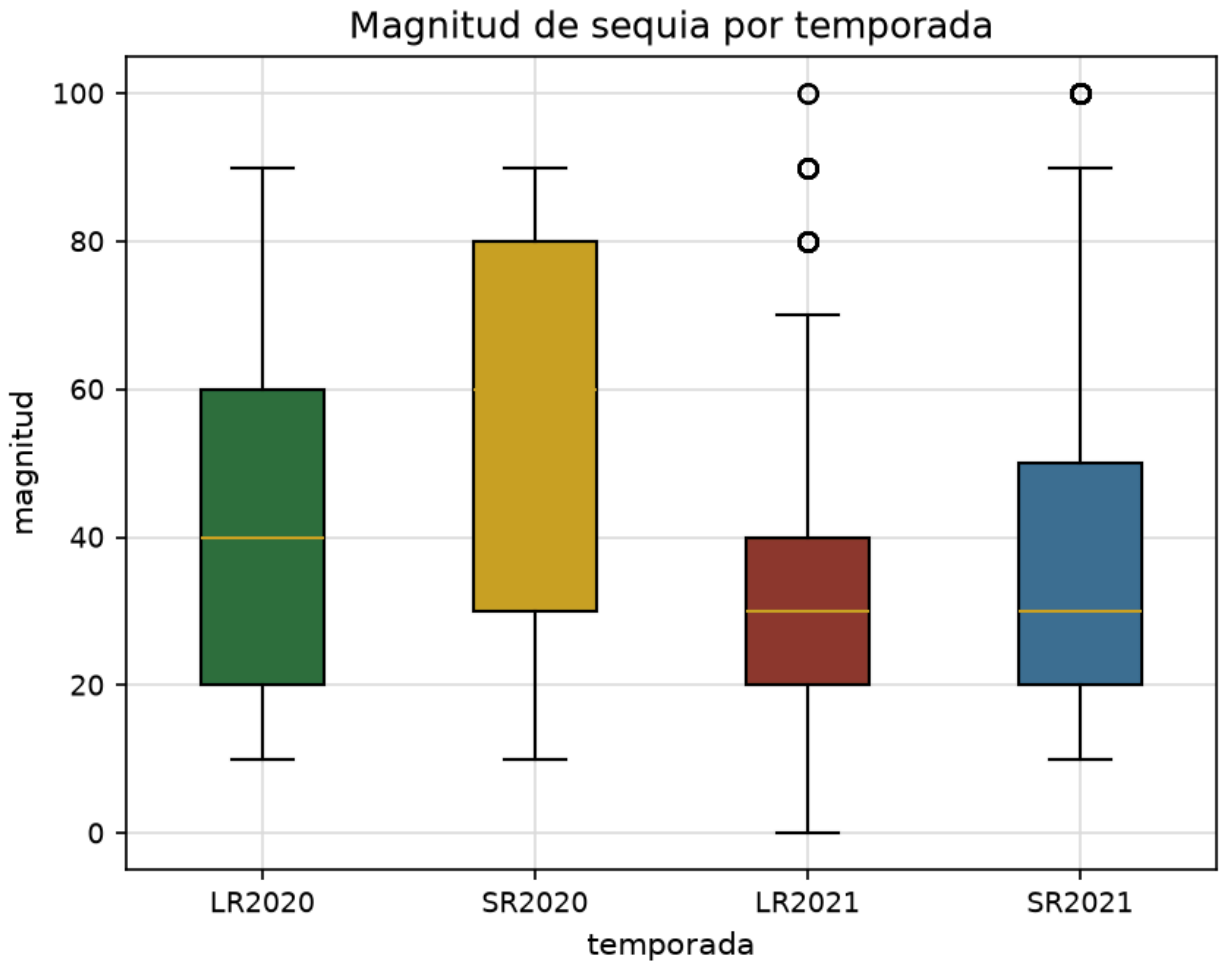


Figura 2. Magnitud de la sequía por temporada.

La sequía se concentra en la madurez: el 48.59 % de los registros en etapa M tiene diagnóstico DR, frente a 13.82 % en F, 4.05 % en V y 0.62 % en S. La asociación sugiere que la etapa influye en la visibilidad o en la anotación del daño, sin demostrar una relación causal.

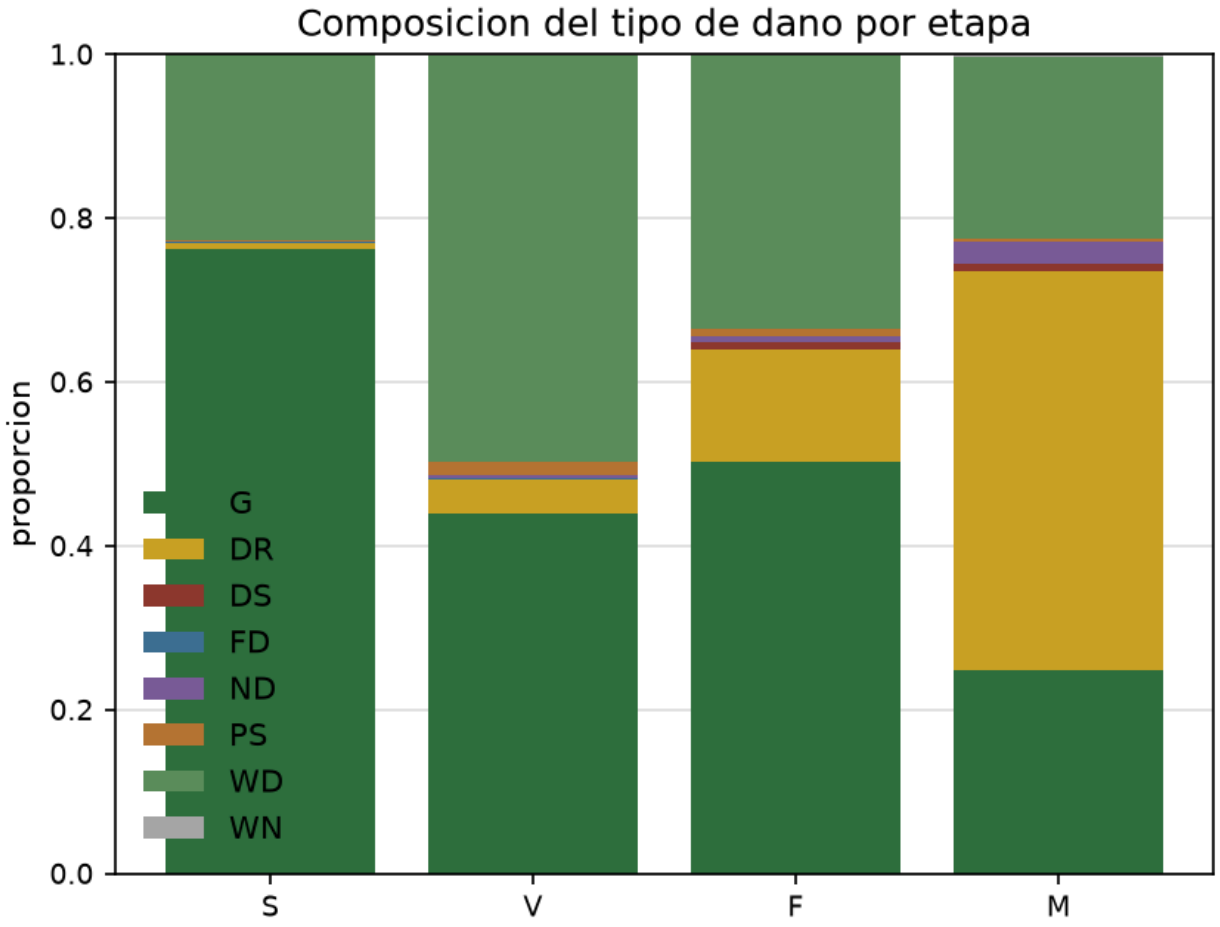


Figura 3. Composición del tipo de daño por etapa.

Asociación entre variables

La V de Cramér más alta se observa entre el daño y la etapa (0.32), seguida por la temporada y el tipo de captura (0.23). El eta cuadrado indica que el daño explica el 69.37 % de la varianza de la magnitud y la etapa, el 19.91 %. La temporada solo explica el 0.84 % en el conjunto completo, porque la gran cantidad de ceros oculta las diferencias que sí aparecen dentro de DR.

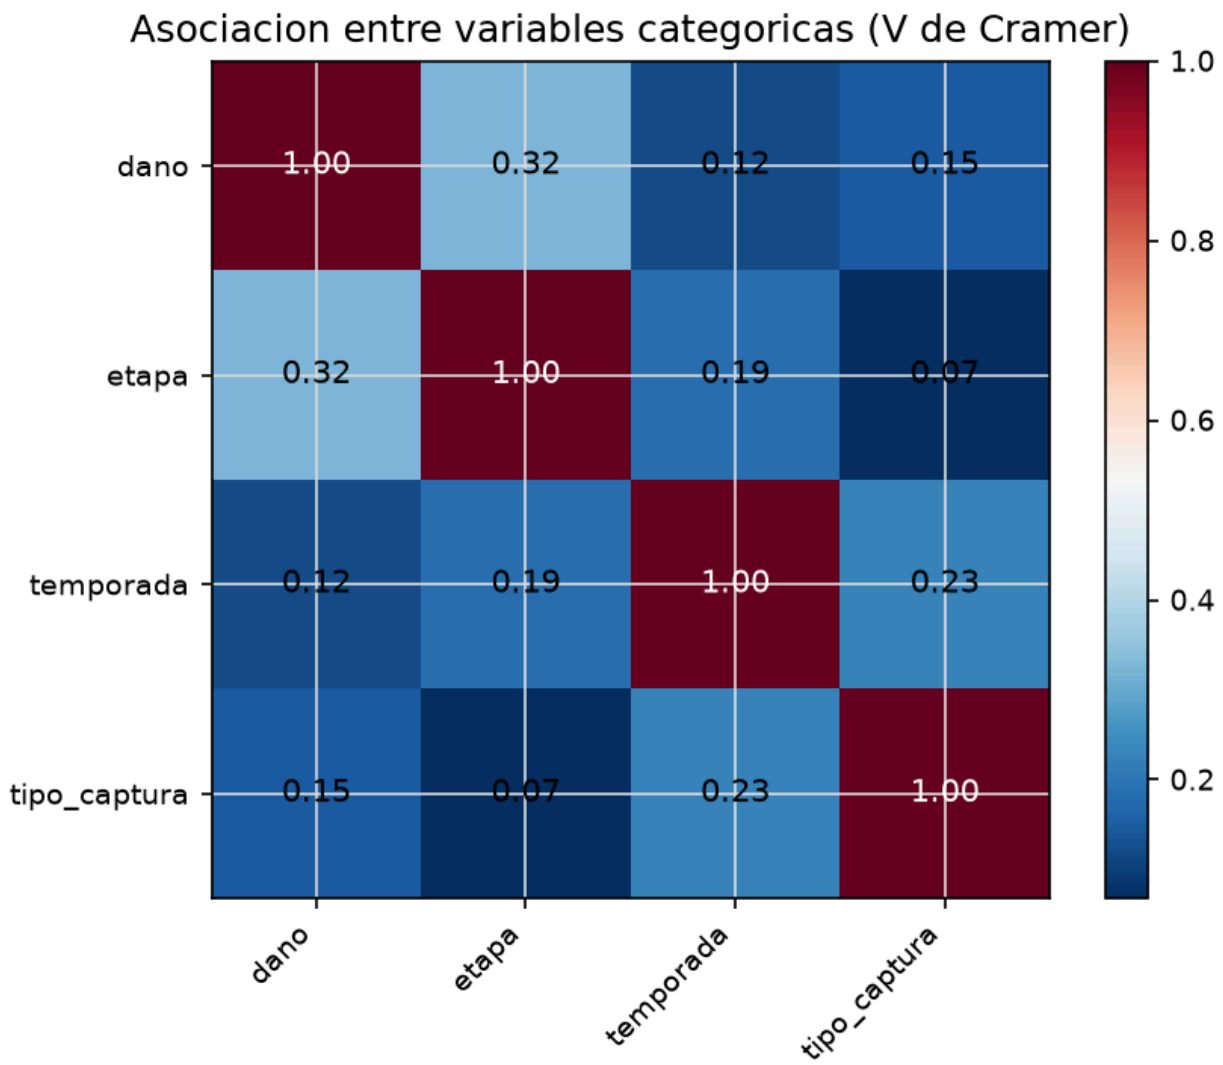


Figura 4. Asociación entre variables categóricas mediante la V de Cramér.

Agrupación por campo

Se identificaron 3 051 campos a partir de los nombres reconocidos. La mediana es de 6 fotografías por campo, el máximo de 60 y el 91.15 % de los campos tiene más de una fotografía. En una simulación de partición aleatoria 80/20, el 87.92 % de los registros de validación perteneció a campos que también estaban en el entrenamiento.

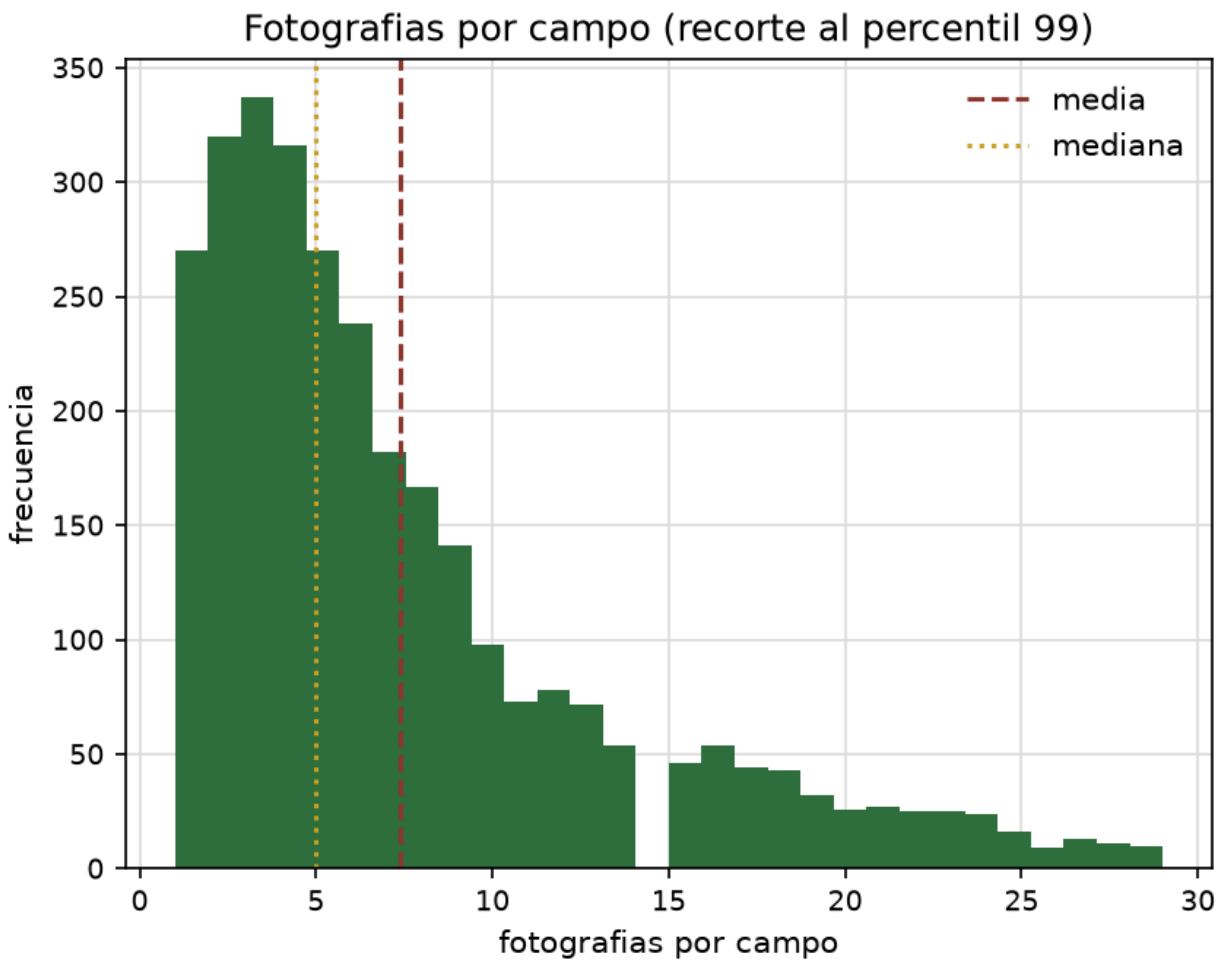


Figura 5. Fotografías por campo, con recorte en el percentil 99.

La partición oficial de Zindi tampoco separa campos: 2 414 campos y 212 productores aparecen en el entrenamiento y en la prueba. Esta es la razón principal para que el proyecto use su propia partición por campo (sección 5.3).

Propiedades técnicas y calidad visual

Todas las fotografías son JPEG. La mediana es de 0.31 megapíxeles y solo el 1.39 % son verticales. LR2020 y SR2020 son por completo de 640 × 480 píxeles. SR2021, en cambio, combina 7 063 imágenes de 320 × 240 con fotografías de varios megapíxeles: el 37.63 % supera los 5 megapíxeles. La prueba de Kolmogórov-Smirnov entre las tres primeras temporadas y SR2021 da su mayor estadístico en los megapíxeles (0.55). La saturación, la exposición, el contraste, el exceso de verde y la nitidez también difieren.

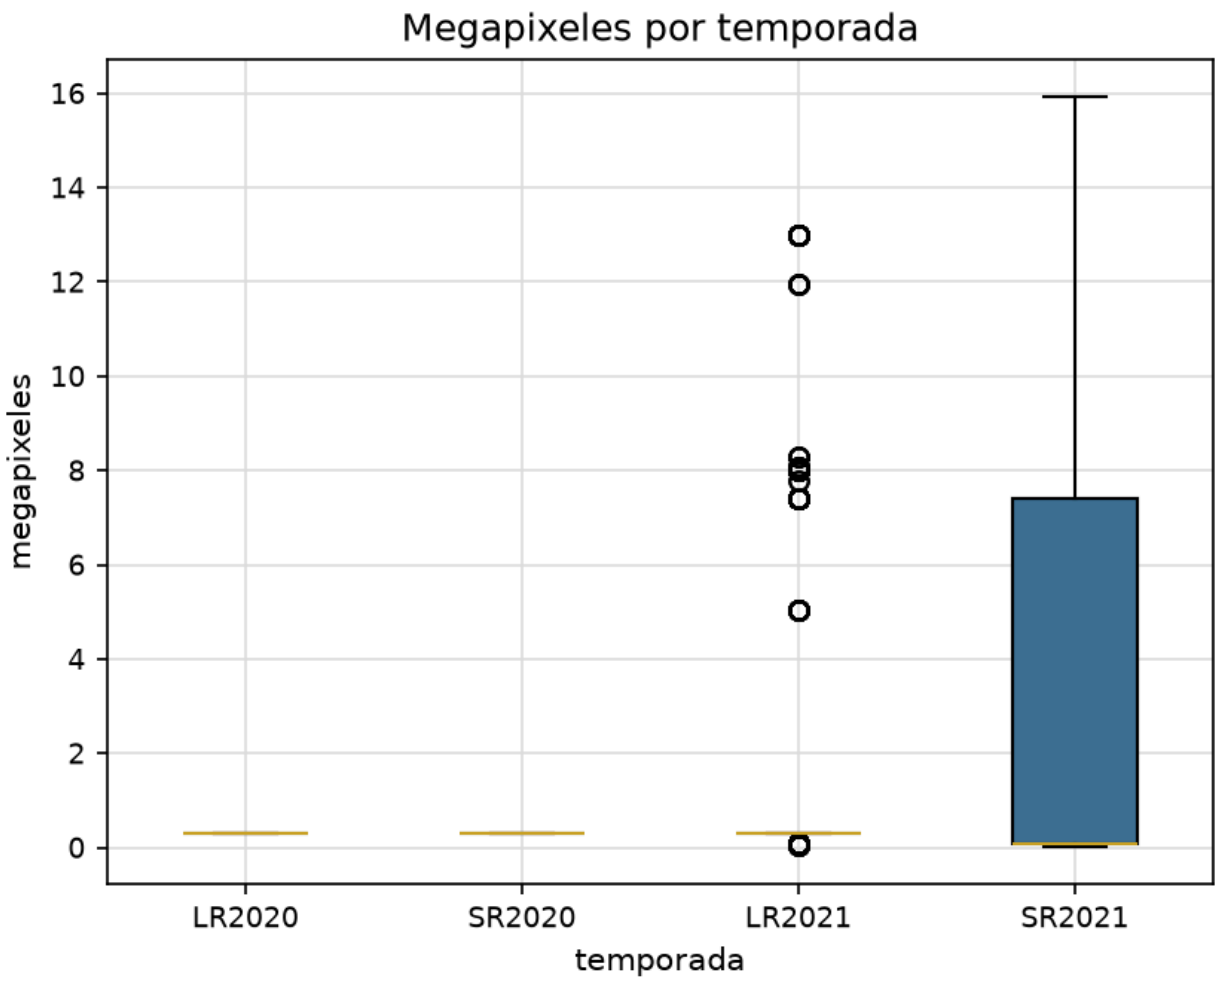


Figura 6. Megapíxeles por temporada.

Con el umbral de nitidez establecido, el 1.82 % de las fotografías se clasifica como desenfocada, proporción que sube a 3.67 % en SR2021. El 3.58 % está mal expuesta. Estas fotografías no se eliminaron: representan las condiciones reales de captura que la aplicación recibirá.



Figura 7. Las diez fotografías con menor nitidez medida.

La huella perceptual agrupó solo 118 imágenes en 51 grupos de fotografías parecidas, y solo 55 imágenes quedaron en grupos mixtos entre entrenamiento y prueba. La inspección de los mosaicos mostró escenas distintas dentro de algunos grupos, así que la duplicación visual es marginal frente al solapamiento por campo.

Relación entre el color y la magnitud

El exceso de verde tiene la asociación monótona más fuerte con la magnitud, con una correlación de Spearman de −0.25. Su promedio baja de 0.15 en magnitud 0 a −0.01 en magnitud 100. La relación es consistente con la pérdida de follaje verde, pero moderada: en cada nivel de magnitud hay fotografías con exceso de verde muy distinto.

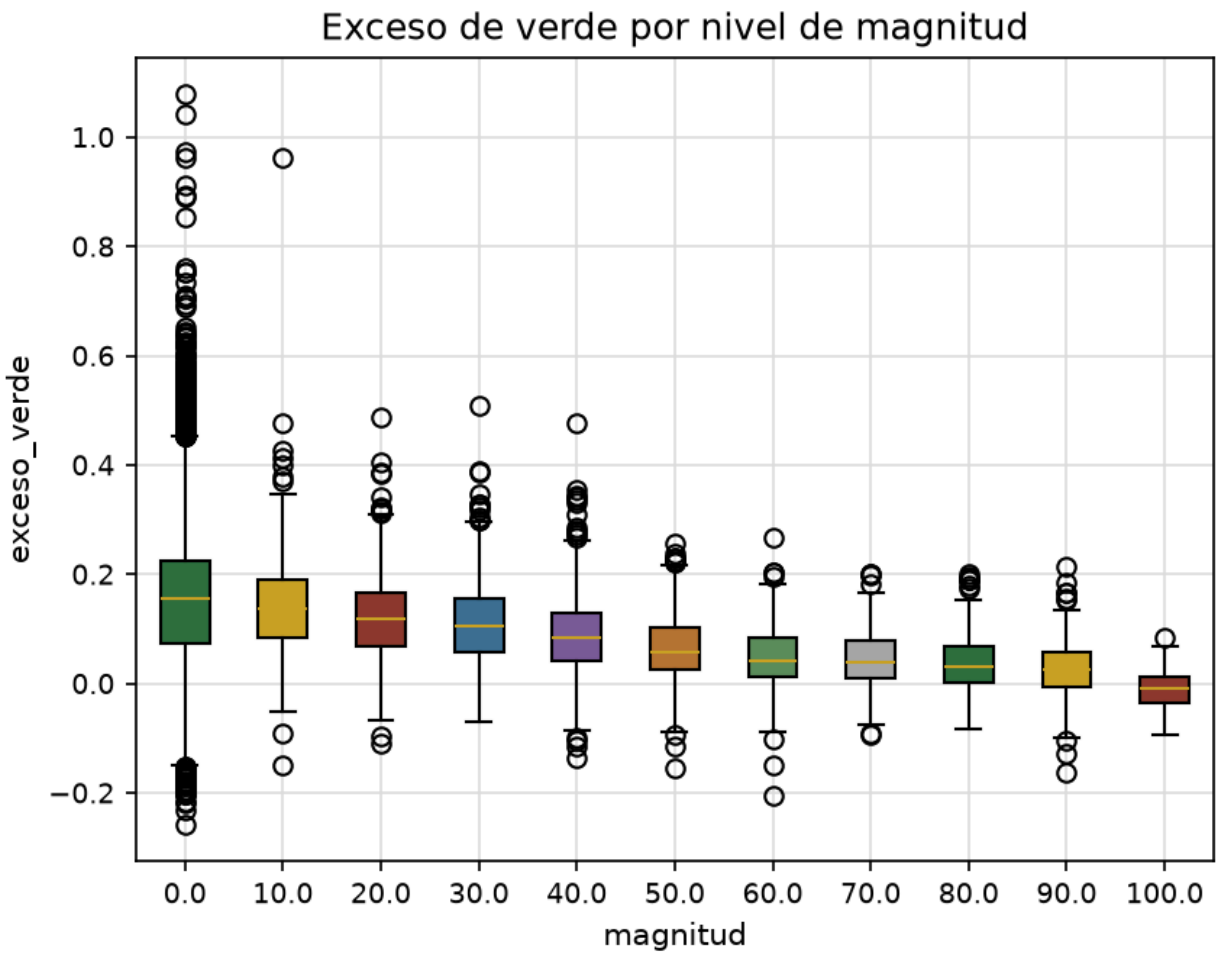


Figura 8. Exceso de verde por nivel de magnitud.

El mosaico por magnitud ilustra el motivo. Fotografías con la misma magnitud muestran encuadres, iluminación, proporción de cielo y suelo y etapas distintas. Un único atributo de color no basta para estimar la severidad, lo que justifica probar modelos que aprendan texturas y estructura de la escena.

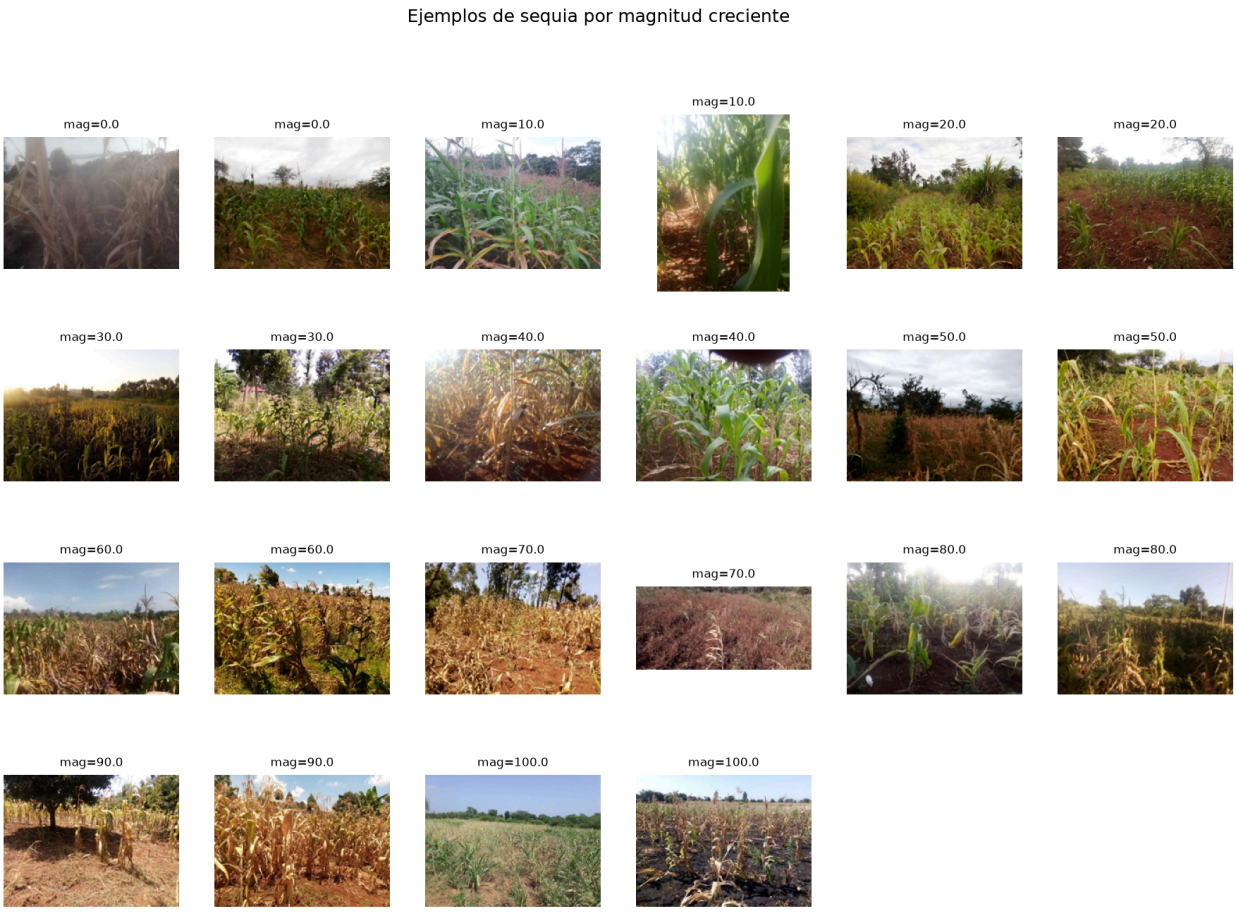


Figura 9. Ejemplos de sequía ordenados por magnitud.

5.5 Implicaciones para el modelado

El análisis exploratorio fijó cinco decisiones de modelado:

1. **Severidad condicionada a sequía.** Los modelos se entrenan solo con registros DR y la regla asigna magnitud cero al resto.
2. **Partición por campo.** Ningún campo aparece en el entrenamiento y en la prueba, ni a ambos lados de la validación.
3. **Métricas en dos alcances.** Se reporta el error dentro de DR, que mide la tarea aprendida, y el global, inflado por los ceros de la regla.
4. **Línea base de color.** Las redes se comparan con un predictor constante y con modelos sobre el exceso de verde y los demás atributos.
5. **Aumentos sin cambio de color.** Las redes reciben recortes y reflejos, pero no alteraciones de tono, porque el color es parte de la señal del daño.

6. Resultados: ajuste y comparación de modelos

6.1 Protocolo de evaluación

Todos los modelos se entrenan con los registros de entrenamiento diagnosticados con sequía (DR): 3 655 fotografías de 1 453 campos. El conjunto de prueba agrupa el 20 % de los campos y contiene 4 628 registros, de los cuales 834 son DR. Los modelos solo estiman la severidad de la sequía. A los registros con otro diagnóstico se les asigna magnitud 0 mediante una regla fija, de modo que todos los modelos se evalúan sobre el mismo conjunto completo.

Se reportan dos alcances:

- **Alcance DR:** mide la tarea que aprenden los modelos sobre los 834 registros con sequía.
- **Alcance global:** incluye los 3 794 registros con otro diagnóstico. En ellos la regla acierta siempre, así que este alcance reduce el error de cualquier modelo.

Por eso la comparación se basa en el alcance DR. Las métricas son el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), todos sobre la escala de 0 a 100. El conjunto de prueba se usó una sola vez por modelo, después de fijar los hiperparámetros. Los seis modelos se entrenaron en el mismo equipo (sección 4.5), así que sus tiempos son comparables entre sí.

6.2 Predictor constante

El predictor constante asigna a cada fotografía DR la magnitud media del entrenamiento, 41.18. No tiene hiperparámetros. Sirve como referencia mínima: un modelo que no lo supera no aprende nada útil de la fotografía. En la prueba DR obtiene MAE de 19.78, RMSE de 24.09 y R^2 prácticamente nulo (−0.001), como corresponde a una predicción que no varía.

6.3 Regresión lineal sobre el exceso de verde

La regresión usa un único atributo, el exceso de verde, que fue el de mayor correlación con la magnitud en el análisis exploratorio. No tiene hiperparámetros. El modelo ajustado es:

$$\overline{magnitud} = 54.46 - 146.79 \cdot ExG$$

La pendiente negativa es coherente con la pérdida de verdor que causa la sequía: un aumento de 0.1 en el exceso de verde reduce la magnitud estimada en unos 14.7 puntos. En la prueba DR obtiene MAE de 17.64, RMSE de 21.44 y R^2 de 0.207. Mejora al predictor constante en 2.6 puntos de RMSE, pero sus predicciones varían poco: la media va de 35.8 para las fotografías con magnitud real 10 a 54.1 para las de magnitud 100.

6.4 Random Forest

El Random Forest usa nueve atributos globales: exceso de verde, saturación, brillo, contraste, las tres medias de canal y las dos proporciones de exposición. La búsqueda probó 30 combinaciones de hiperparámetros con validación cruzada de cinco pliegues agrupados por campo. Las cuatro mejores fueron:

Tabla 6.1. Mejores combinaciones de la búsqueda del Random Forest.

Árboles	Hoja mínima	Atributos por división	Profundidad máxima	RMSE validación	MAE validación
200	10	raíz cuadrada	10	**20.65**	16.43
300	20	0.5	sin límite	20.67	16.43
100	20	0.5	20	20.67	16.44
200	10	0.5	10	20.68	**16.41**

Las 30 combinaciones quedan entre 20.65 y 21.04 de RMSE de validación, así que el error depende poco de los hiperparámetros. Entre las mejores predominan hojas de 10 a 20 registros, que suavizan las predicciones. Las peores limitan la profundidad a 5 o combinan hojas de un solo registro con todos los atributos. La combinación elegida se reajustó con todo el entrenamiento DR.

Atributos del dispositivo. El análisis exploratorio mostró que los megapíxeles y la nitidez cambian con la temporada y pueden describir el teléfono más que el daño. Agregarlos baja el RMSE de validación de 20.65 a 20.39, una mejora menor que la diferencia entre combinaciones de la búsqueda. Como la validación mezcla las cuatro temporadas, no permite saber si esa ganancia viene del daño o de reconocer la temporada por el teléfono. Por eso el modelo final los excluye.

Importancia de los atributos. El exceso de verde concentra 0.47 de la importancia, casi cuatro veces más que el siguiente atributo, la media del canal rojo (0.12). El resultado coincide con el análisis exploratorio y confirma que ese índice resume buena parte de la señal de color de la sequía.

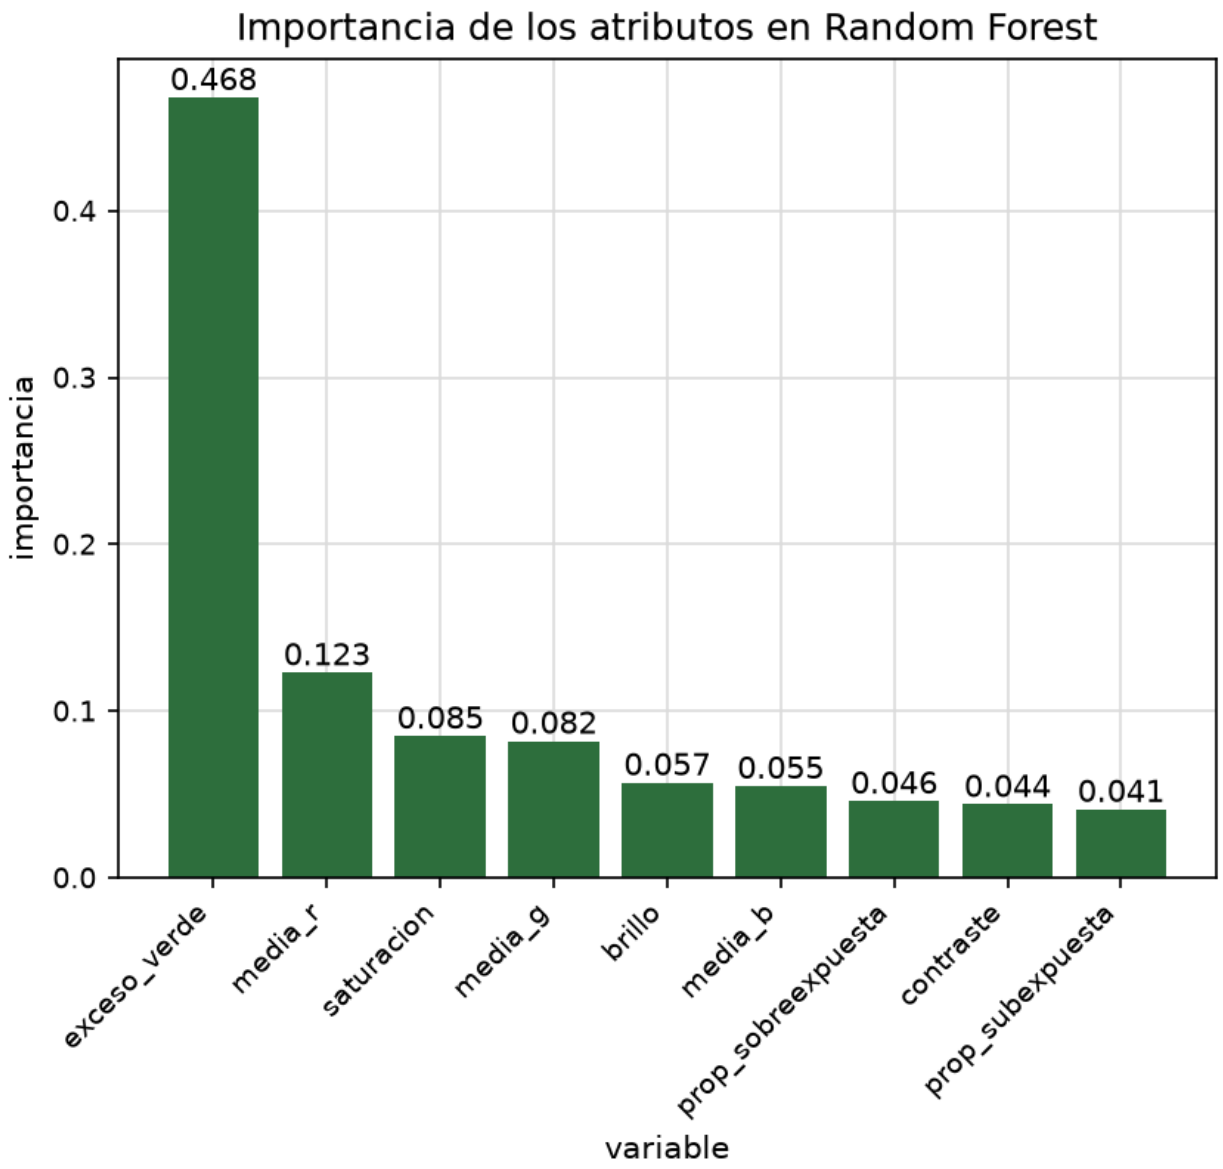


Figura 10. Importancia de los atributos en el Random Forest.

Generalización temporal. Dentro del entrenamiento DR, se entrenó el Random Forest con LR2020, SR2020 y LR2021 y se evaluó en SR2021. Obtuvo un RMSE de 20.53, muy cercano al 20.65 de la validación por campo, mientras que predecir la media de las temporadas anteriores llega a 24.19. No se observa una caída al cambiar de temporada. El resultado es en parte optimista: 353 de los 732 campos de SR2021 también aparecen en las temporadas anteriores y concentran el 53 % de sus registros.

En la prueba DR, el Random Forest obtiene MAE de 16.68, RMSE de 20.61 y R^2 de 0.267. La búsqueda completa y el reajuste tardaron 23 segundos en la CPU, y la inferencia es de 0.02 ms por registro, porque parte de los atributos ya calculados.

6.5 ResNet50

La ResNet50 parte de los pesos de ImageNet y reemplaza la capa de clasificación por una neurona lineal que predice la magnitud dividida entre 100. El procedimiento es el mismo que el de DenseNet121, para

que las diferencias entre ambas redes reflejen la arquitectura y no la configuración.

La búsqueda probó dos tasas de aprendizaje y dos niveles de ajuste fino. Los niveles fueron entrenar solo la capa de salida (`cabeza`) o también el último bloque convolucional (`ultimo_bloque`). Cada configuración se entrenó con parada temprana sobre un pliegue de validación de 731 fotografías, cuyos campos no aparecen en las 2 924 de ajuste.

Tabla 6.2. Configuraciones probadas para ResNet50.

Tasa de aprendizaje	Capas entrenadas	Mejor época	RMSE validación	MAE validación
3×10^{-4}	`ultimo_bloque`	2	**17.99**	**13.85**
1×10^{-4}	`cabeza`	13	18.34	14.33
3×10^{-4}	`cabeza`	7	18.59	14.60
1×10^{-4}	`ultimo_bloque`	7	18.74	14.52

Se eligió la configuración con menor RMSE de validación: tasa de 3×10^{-4}, último bloque descongelado y 2 épocas. Con ella se reentrenó la red sobre las 3 655 fotografías DR de entrenamiento.

Las cuatro configuraciones quedan a menos de un punto de RMSE entre sí, así que el resultado depende poco de estos hiperparámetros. La curva de la configuración elegida muestra que la pérdida de validación alcanza su mínimo en la segunda época. Después sube, mientras la de entrenamiento sigue bajando: al ajustar el último bloque, la red memoriza pronto las fotografías de ajuste. Solo con la cabeza el aprendizaje es más lento (13 épocas) y llega a un error casi igual.

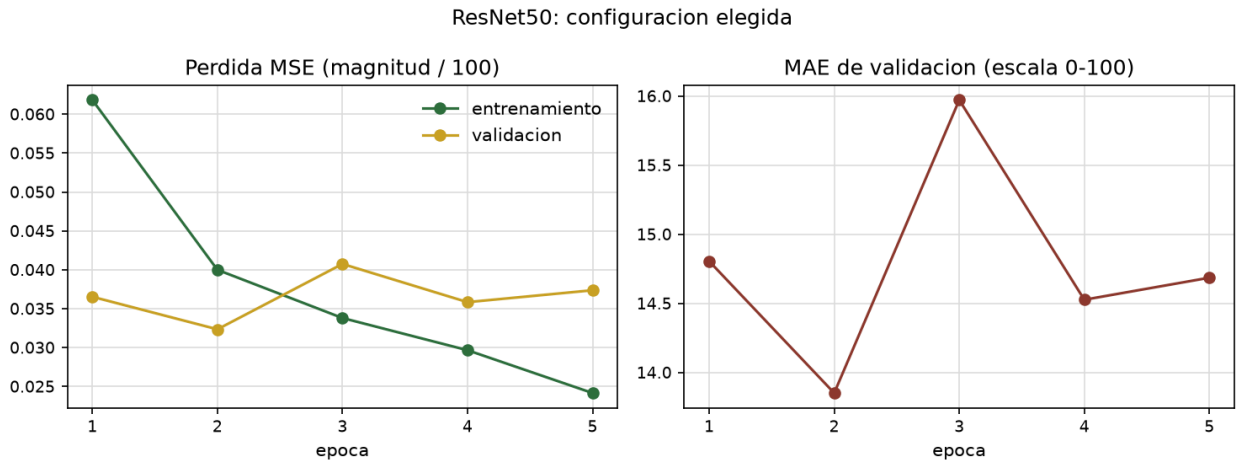


Figura 11. Pérdida y MAE de validación por época de la configuración elegida de ResNet50.

En la prueba DR obtiene MAE de 14.61, RMSE de 18.33 y R^2 de 0.420. La búsqueda de cuatro configuraciones y el reentrenamiento final tardaron 10.3 minutos, y la inferencia promedió 20.3 ms por fotografía, incluida la lectura del archivo.

6.6 ResNet50 ajustada

La ResNet50 anterior sigue el procedimiento común de las redes convolucionales, para que su comparación con DenseNet121 refleje solo la arquitectura. Para saber cuánto mejora la misma arquitectura con otra receta de entrenamiento, se entrenó una segunda versión, la ResNet50 ajustada. Se registró como un modelo aparte, sin modificar la primera.

La receta se eligió con experimentos sobre el entrenamiento DR, sin usar la prueba. Primero se probaron siete cambios, uno a la vez, sobre el pliegue 0. La mayoría movió el RMSE de validación menos de un punto, dentro de la variación de la base entre una época y otra (de 18.1 a 19.7). Los cambios que redujeron el error se combinaron en una receta:

Tabla 6.3. Receta de la ResNet50 frente a la ResNet50 ajustada.

Elemento	ResNet50	ResNet50 ajustada
Pesos iniciales	`IMAGENET1K_V1`	`IMAGENET1K_V2`
Capas entrenadas	Cabeza o último bloque	Toda la red
Tasa de aprendizaje	Una sola, 10^{-4} o 3×10^{-4}	10^{-3} en la salida y 10^{-4} en el resto
Programa de la tasa	Constante	Coseno de 10 épocas
Selección de época	Parada temprana sobre validación	Última época
Tamaño de entrada	224	320
Predicción	Imagen centrada	Promedio de la imagen y su reflejo horizontal

Los cambios descartados fueron la pérdida de Huber y descongelar solo los dos últimos bloques, que empeoraron el error, y los aumentos más agresivos, que no lo cambiaron.

La receta se fijó en el pliegue 0 y se evaluó en los pliegues 1 y 2 con la política fija, sin volver a elegir la época. Para la ResNet50 se usó la época 2, la que eligió su búsqueda. Estos experimentos de selección se hicieron en la etapa de diseño de la receta:

Tabla 6.4. RMSE de validación por pliegue durante la selección de la receta.

Pliegue	ResNet50, época 2	ResNet50 ajustada, época 10
0	18.09	18.02
1	19.23	17.16
2	21.43	18.55
Media	19.58	17.91

En el pliegue 0 ambas empatan, pero ahí la época de la ResNet50 se eligió con el mismo pliegue, lo que favorece su resultado. En los pliegues 1 y 2 la receta ajustada reduce el RMSE en 2 a 3 puntos. La receta también es más estable: con el programa coseno, la validación cambia poco en las últimas épocas y no hace falta elegir una época sobre un pliegue ruidoso.

El tamaño de entrada fue el cambio que más ayudó. El cuaderno de entrenamiento repite esa elección sobre el pliegue 0: la entrada de 320 obtiene un RMSE de validación de 17.43, frente a 18.39 con 224. Después reentrena con las 3 655 fotografías DR durante 10 épocas.

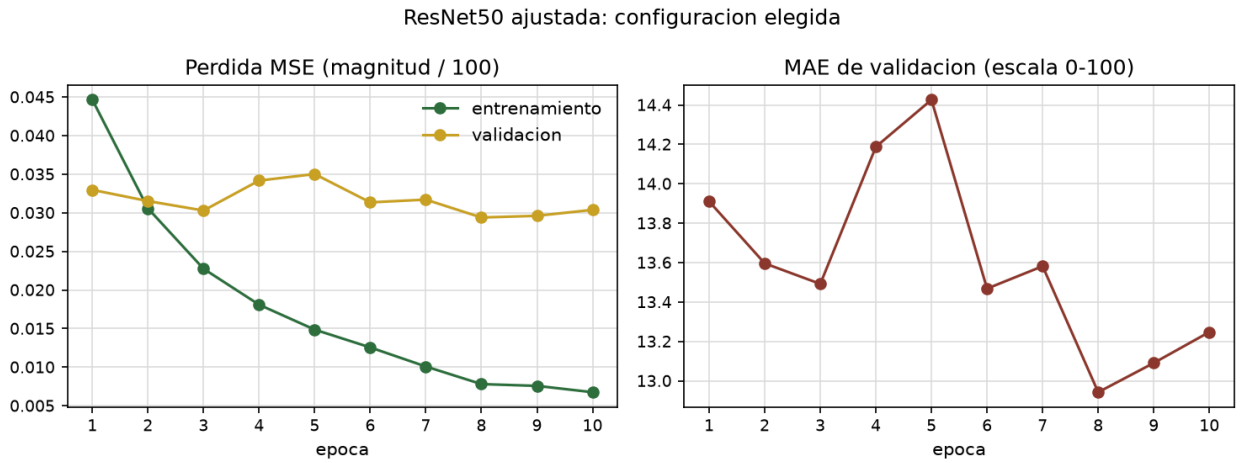


Figura 12. Pérdida y MAE de validación por época de la ResNet50 ajustada.

En la prueba DR obtiene MAE de 13.50, RMSE de 17.84 y R^2 de 0.451. El proceso completo tardó 17.0 minutos y la inferencia promedia 30.8 ms por fotografía. Es la red más lenta, por la entrada mayor y porque cada fotografía se procesa dos veces.

6.7 DenseNet121

DenseNet121 sigue el mismo procedimiento común que la ResNet50. En esta red, `cabeza` entrena solo la capa lineal de salida y `ultimo_bloque` entrena además el cuarto bloque denso y la normalización final.

Tabla 6.5. Configuraciones probadas para DenseNet121.

Tasa de aprendizaje	Capas entrenadas	Mejor época	RMSE validación	MAE validación
3×10^{-4}	`cabeza`	14	**18.92**	**14.89**
1×10^{-4}	`ultimo_bloque`	11	19.26	15.18
1×10^{-4}	`cabeza`	15	19.82	15.62
3×10^{-4}	`ultimo_bloque`	2	20.92	16.34

Se eligió la tasa de 3×10^{-4} entrenando solo la cabeza, durante 14 épocas. A diferencia de la ResNet50, la mejor configuración no ajusta el último bloque. Con la tasa mayor, ajustar el cuarto bloque denso sobreajustó desde la segunda época y dio el peor resultado. Con la tasa menor, en cambio, el último bloque mejoró a la cabeza sola. La cabeza sola aprende despacio: con 10^{-4} seguía mejorando en la época 15, el máximo permitido.

La curva de la configuración elegida baja de forma sostenida y casi sin separación entre entrenamiento y validación. Con los bloques congelados, la red no memoriza las fotografías de ajuste, pero tampoco adapta sus filtros a las señales de la sequía.

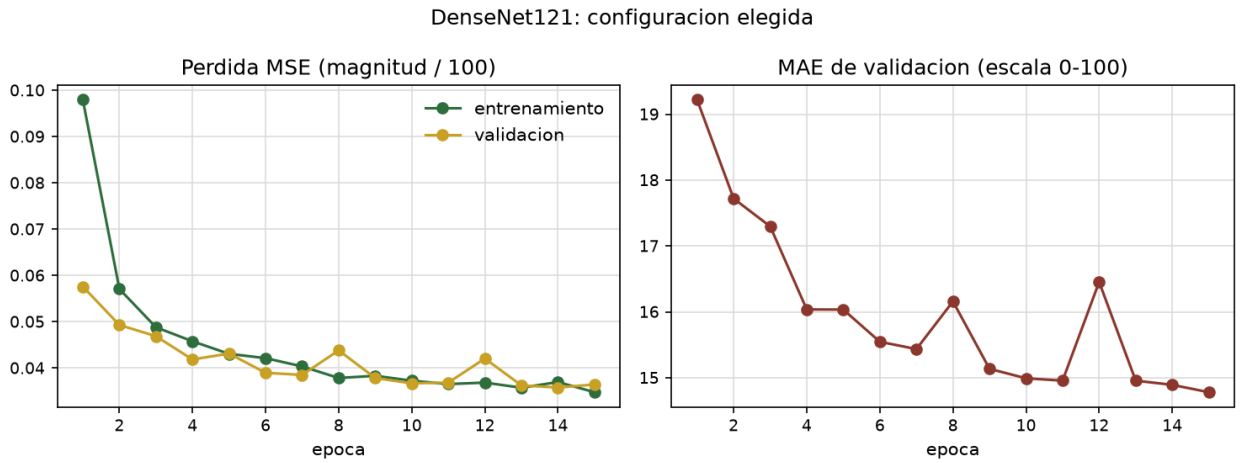


Figura 13. Pérdida y MAE de validación por época de la configuración elegida de DenseNet121.

En la prueba DR obtiene MAE de 15.58, RMSE de 19.36 y R^2 de 0.354. La búsqueda y el reentrenamiento tardaron 14.2 minutos, y la inferencia promedia 24.4 ms por fotografía.

6.8 Comparación

Tabla 6.6. Métricas de prueba y tiempos de los seis modelos.

Modelo	MAE DR	RMSE DR	R^2 DR	MAE global	RMSE global	R^2 global	Entrenamiento (s)	Inferencia (ms)
ResNet50 ajustada	**13.50**	**17.84**	**0.451**	**2.43**	**7.57**	**0.835**	1 021	30.8
ResNet50	14.61	18.33	0.420	2.63	7.78	0.826	620	20.3
DenseNet121	15.58	19.36	0.354	2.81	8.22	0.806	850	24.4
Random Forest	16.68	20.61	0.267	3.01	8.75	0.780	23	0.02
Regresión sobre exceso de verde	17.64	21.44	0.207	3.18	9.10	0.762	0.06	< 0.01
Predictor constante	19.78	24.09	−0.001	3.57	10.22	0.699	< 0.001	< 0.001

Los cinco modelos superan al predictor constante, y el orden es claro: las redes convolucionales mejoran más que los modelos sobre atributos globales. El Random Forest reduce el RMSE DR en 14.4 % respecto del predictor constante; DenseNet121, en 19.6 %; la ResNet50, en 23.9 %, y la ResNet50 ajustada, en 25.9 %. El salto entre el Random Forest y la mejor red, casi tres puntos de RMSE, muestra que la textura y la estructura de la escena aportan información que los promedios de color no capturan.

En todos los modelos el RMSE de prueba es cercano al de validación: 20.61 contra 20.65 en el Random Forest, 18.33 contra 17.99 en la ResNet50, 17.84 contra 17.43 en la ajustada y 19.36 contra 18.92 en DenseNet121. Esto indica que la partición por campo dio una estimación honesta del error.

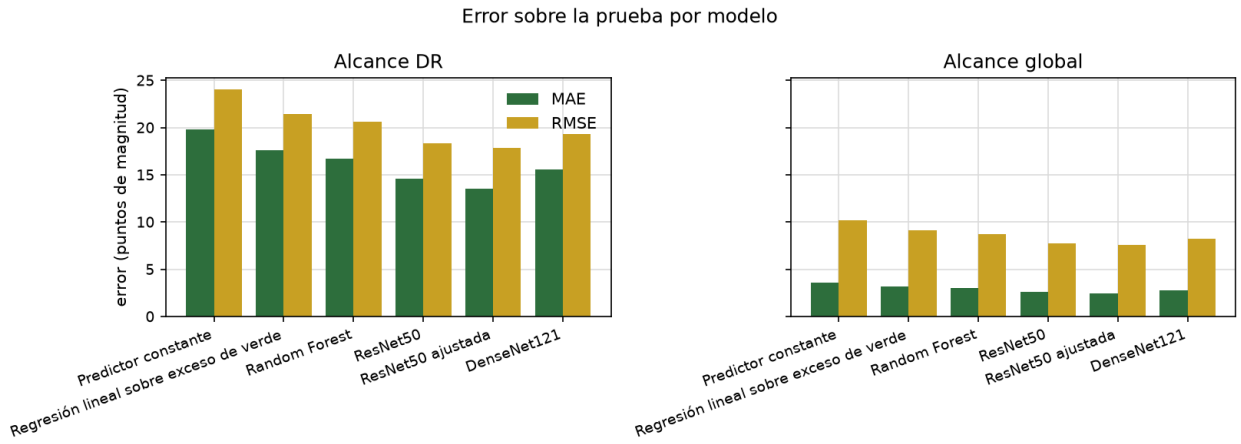


Figura 14. MAE y RMSE de cada modelo sobre la prueba, en los alcances DR y global.

Arquitectura. Con el mismo procedimiento, la ResNet50 supera a DenseNet121 por un punto de RMSE. Para saber si la diferencia es real, se remuestrearon con reemplazo las 834 fotografías DR de prueba 5 000 veces (bootstrap pareado). La ResNet50 baja el RMSE en 1.02 puntos, con un intervalo de confianza al 95 % de −1.65 a −0.38, y el MAE en 0.97 puntos (de −1.54 a −0.40). Ningún intervalo incluye el cero, así que en este problema la ResNet50 es la mejor arquitectura de las dos. Una explicación probable es que DenseNet121 eligió no ajustar sus bloques, mientras que la ResNet50 sí adaptó su último bloque.

Receta. El mismo bootstrap compara las dos ResNet50:

- **MAE:** la ajustada baja 1.11 puntos, con un intervalo de −1.81 a −0.42. Como el intervalo no incluye el cero, la mejora es significativa.
- **RMSE:** la ajustada baja 0.49 puntos, con un intervalo de −1.33 a 0.38 y una probabilidad de mejora del 86.9 %.

En el alcance global los errores bajan y el R^2 sube para todos los modelos, porque la regla acierta en los 3 794 registros con otro diagnóstico. Esa mejora no se debe al modelo y no debe leerse como capacidad para estimar la severidad.

Compresión hacia el centro. La gráfica de magnitud real contra predicha muestra la principal limitación de todos los modelos: comprimen sus predicciones hacia el centro de la escala. Sobrestiman los daños leves y subestiman los severos:

Tabla 6.7. Predicción media por nivel de magnitud real en la prueba DR.

Magnitud real	10	40	60	90	100
Random Forest	34.2	40.7	48.6	55.3	55.2
DenseNet121	30.4	42.8	56.3	61.9	67.2
ResNet50	31.1	43.7	55.5	65.7	69.7
ResNet50 ajustada	25.8	39.2	53.4	68.3	62.9

Los modelos sobre atributos casi no distinguen los daños severos: el Random Forest predice cerca de 55 para todas las fotografías con magnitud 80 o más. Las redes abren más la escala. La ajustada corrige buena parte del sesgo en los daños leves, que son los más frecuentes. Con solo 9 fotografías de magnitud 100 en la prueba, la media de ese nivel es poco estable.

La predicción media crece con la magnitud real, así que las redes ordenan bien las fotografías por severidad aunque no acierten el valor exacto. Las predicciones DR que quedan cerca del valor real son:

Tabla 6.8. Proporción de predicciones DR cercanas al valor real.

Distancia al valor real	Random Forest	DenseNet121	ResNet50	ResNet50 ajustada
10 puntos o menos	35.5 %	39.0 %	41.8 %	48.3 %
20 puntos o menos	65.8 %	68.6 %	73.4 %	77.3 %

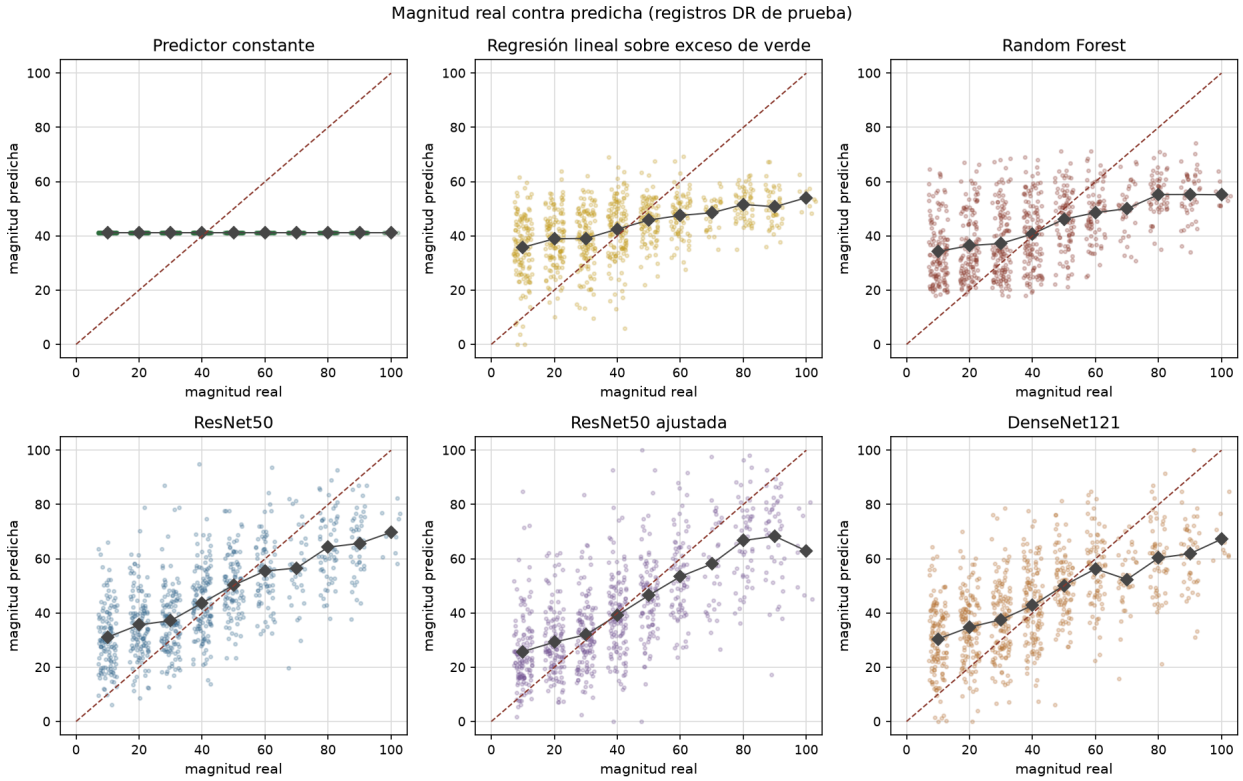


Figura 15. Magnitud real contra predicha en los registros DR de prueba.

Temporadas. Todos los modelos mejoran al predictor constante en las cuatro temporadas. La ganancia mayor se da en SR2020, donde el RMSE baja de 30.04 a 20.10 con la ResNet50 ajustada. En esa temporada las magnitudes se alejan más de la media general, por lo que el predictor constante falla más. SR2020 sigue siendo la temporada más difícil para todos los modelos, lo que sugiere que sus condiciones de captura influyen en el error. La ResNet50 ajustada tiene el menor RMSE en las cuatro temporadas, de 15.52 en LR2020 a 20.10 en SR2020.

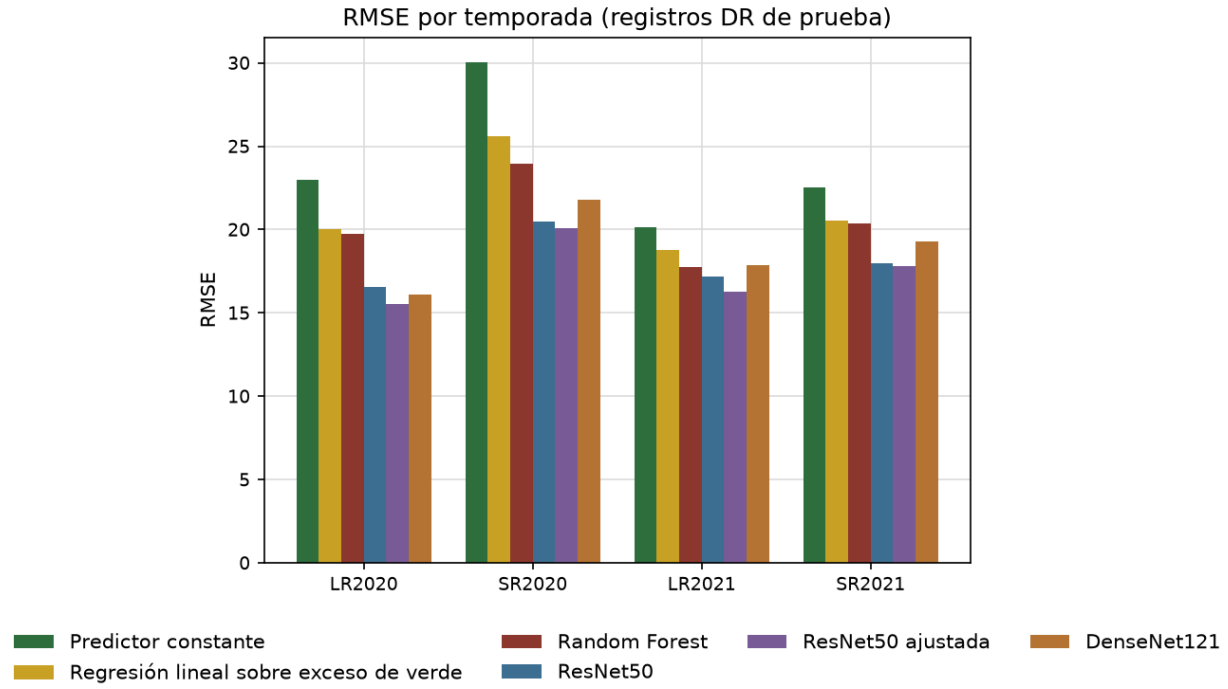


Figura 16. RMSE por temporada en los registros DR de prueba.

Tiempos. Los modelos sobre atributos se entrenan en segundos y predicen en centésimas de milisegundo, sin contar la extracción de atributos. Las redes requieren de 10 a 17 minutos de entrenamiento en la GPU y de 20 a 31 ms por fotografía. Todos los costos de inferencia son compatibles con la aplicación, que responde a cada fotografía en línea.

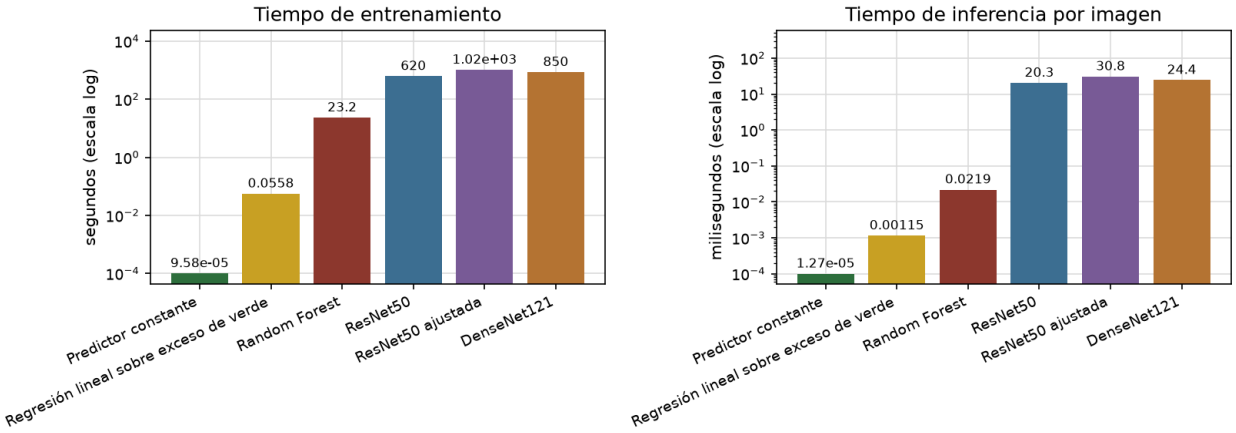


Figura 17. Tiempo de entrenamiento y de inferencia por modelo, en escala logarítmica.

Recomendación. El criterio de selección usa el RMSE DR. Si dos modelos quedan a menos de un punto, prefiere el de menor tiempo de inferencia. Las dos ResNet50 quedan a 0.49 puntos, así que el criterio recomienda la ResNet50 del procedimiento común, que predice en dos tercios del tiempo. Si la latencia no es una restricción, la ResNet50 ajustada es la de menor error en todas las métricas, y su ventaja en MAE es significativa.

7. Aplicación

La aplicación web presenta los datos, los modelos y sus resultados de forma interactiva. Está construida con React y TypeScript sobre Vite, con componentes de estilo neobrutalista, gráficos de Recharts y una paleta agrícola de verde, oro y terracota. Se comunica con la API de FastAPI mediante un cliente tipado que se genera desde el contrato OpenAPI del proyecto, de modo que cualquier cambio en el contrato se refleja de inmediato en los tipos del código.

La escala de magnitud del daño usa un degradado continuo de verde a terracota. El color nunca aparece solo: siempre acompaña al número o a una etiqueta, y la paleta se verificó para contraste WCAG AA y para distinguirse con los tipos más comunes de daltonismo. Cuando la API no responde o faltan datos o modelos, cada página muestra un aviso con la instrucción para resolverlo en lugar de quedar vacía.

La aplicación tiene cinco páginas y muestra los datos y los resultados reales del proyecto. La página de inicio resume el estado de la API, el tamaño del conjunto (23 350 fotografías de 3 051 campos, 4 489 con sequía) y la partición entre entrenamiento y prueba.



Figura 18. Página de inicio con el estado del sistema y el resumen del conjunto.

La página de exploración muestra la composición del conjunto, un histograma configurable por variable, agrupación e intervalos, la dispersión de cada atributo contra la magnitud y la correlación de Spearman. Al final incluye una tabla de registros con filtros, orden por columna y paginación.

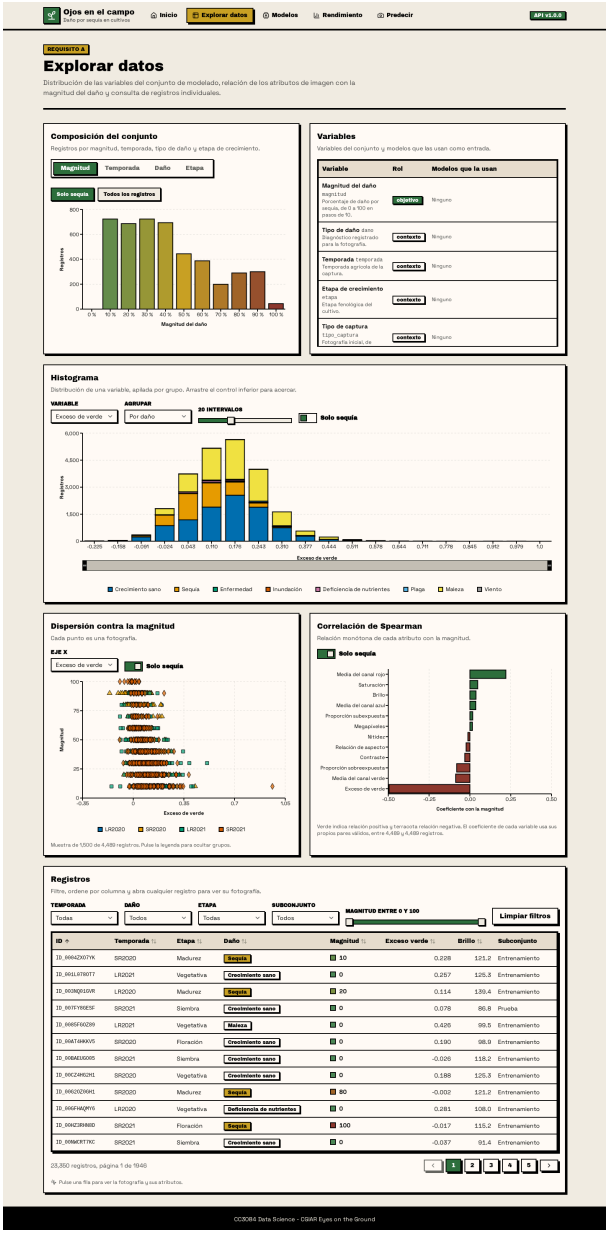


Figura 19. Página de exploración de datos.

Al abrir un registro se muestra su fotografía junto con sus atributos y su diagnóstico. La figura muestra una fotografía de prueba con sequía de magnitud 100: el suelo queda expuesto y el exceso de verde es negativo.

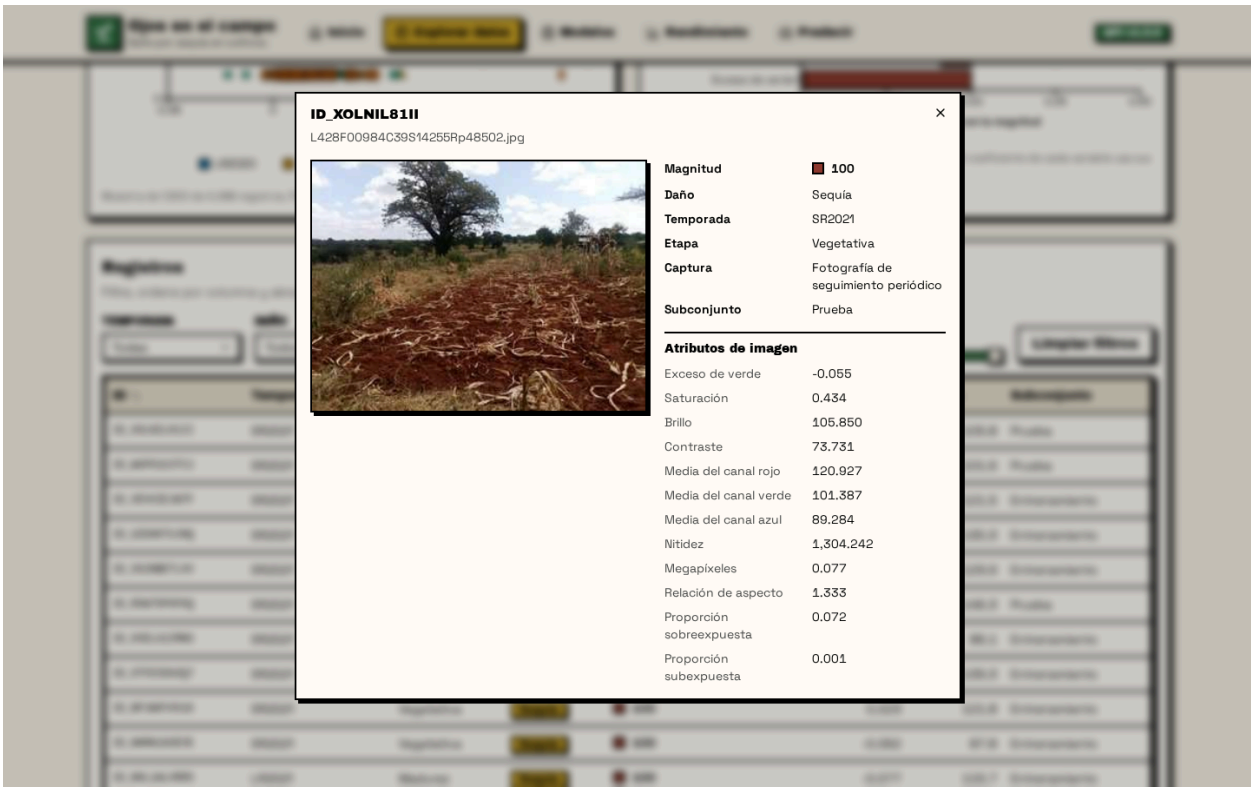


Figura 20. Detalle de un registro con su fotografía.

La página de modelos describe cada algoritmo: su familia, las variables que usa, los hiperparámetros elegidos, el historial de la búsqueda de hiperparámetros, la curva de entrenamiento y la importancia de las variables cuando el modelo las reporta. La figura muestra las cuatro configuraciones evaluadas para DenseNet121, con la elegida resaltada en terracota.

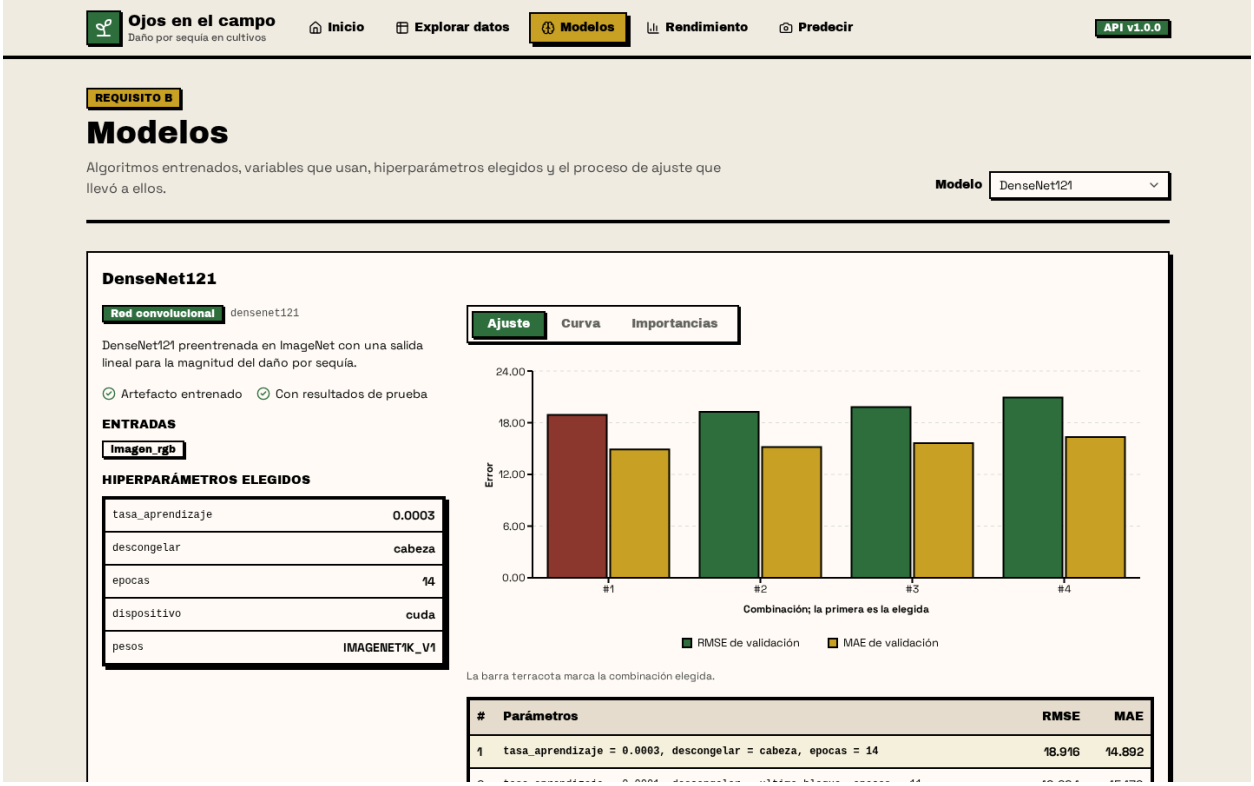


Figura 21. Página de modelos.

La página de rendimiento compara los seis modelos sobre el conjunto de prueba. Muestra MAE, RMSE, R^2 y tiempos de entrenamiento e inferencia, el gráfico de valor real contra predicho, la distribución del error y el error por temporada, etapa o magnitud. La evaluación puede limitarse a los registros con sequía o abarcar todo el conjunto de prueba, y cada modelo puede mostrarse u ocultarse desde la leyenda.

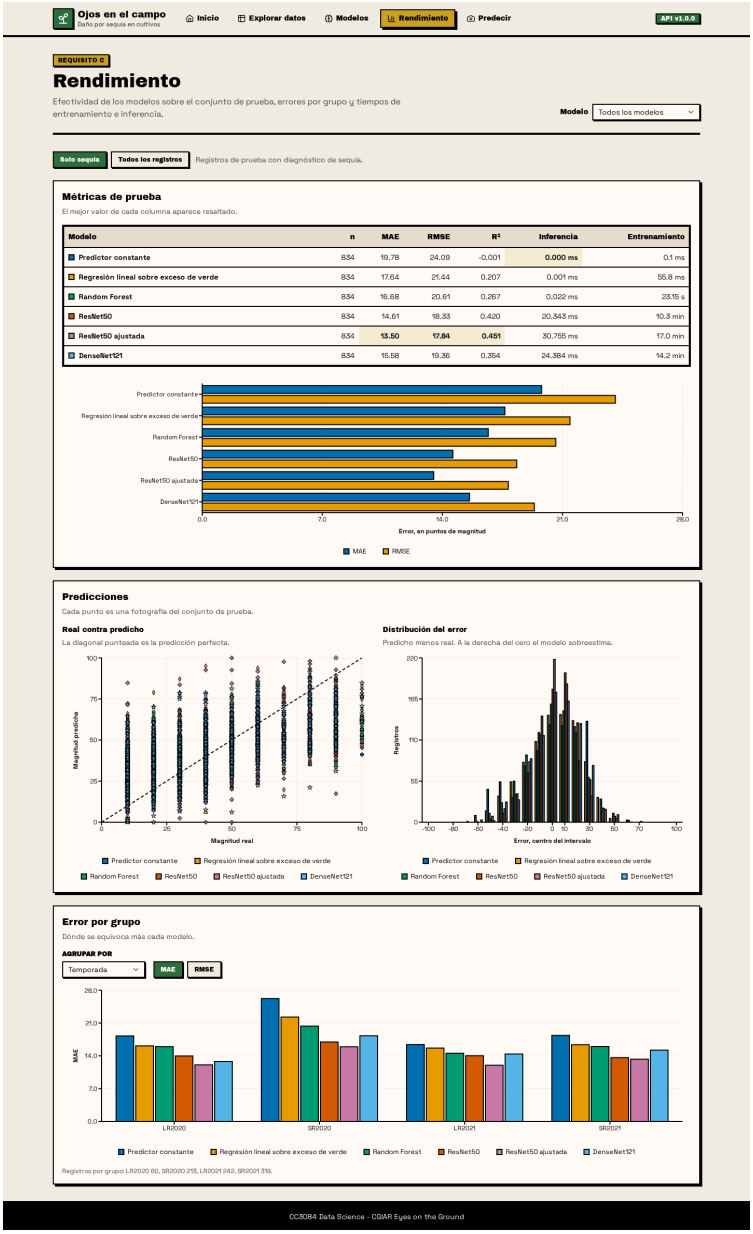


Figura 22. Página de rendimiento de los modelos.

La página de predicción recibe una fotografía JPEG o PNG, un diagnóstico opcional y los modelos a consultar. Devuelve la magnitud estimada por cada modelo, redondeada a la decena más cercana, e indica cuándo se aplica la regla que fija la magnitud en 0 para diagnósticos distintos de sequía. Antes de estimar, la API calcula los atributos de la fotografía y aplica a cada red su propia transformación, sin que el usuario intervenga. La figura usa una fotografía de prueba con magnitud real de 60, elegida para ilustrar el resultado: las tres redes y el Random Forest estiman entre 50 y 60, mientras que el predictor constante devuelve siempre 40.

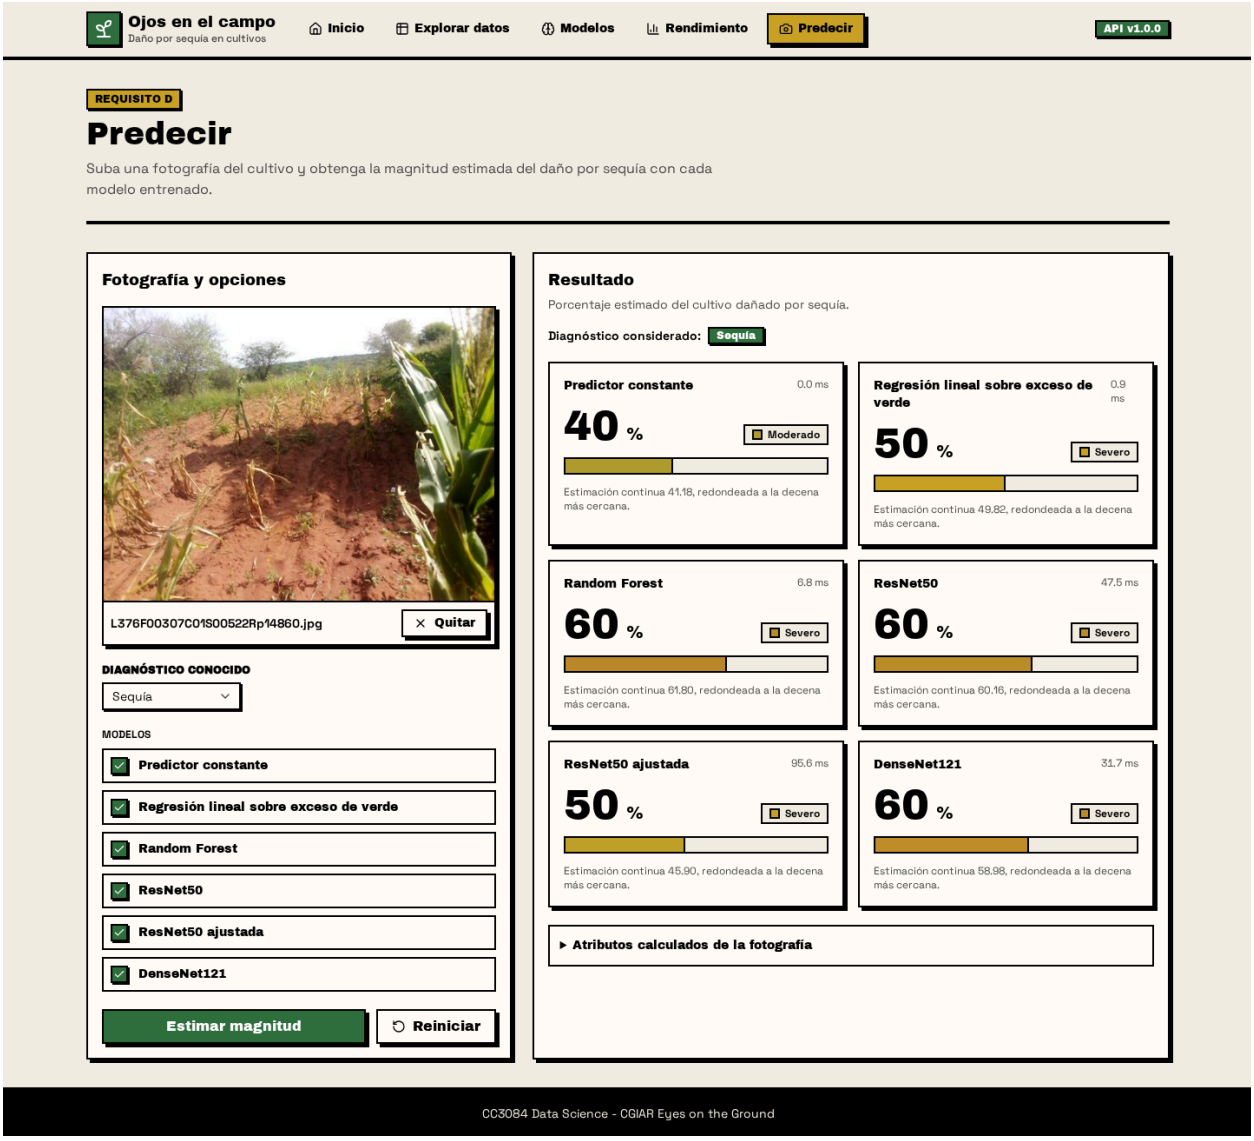


Figura 23. Página de predicción con el resultado de una fotografía.

Las capturas se tomaron con los datos y los modelos reales del proyecto. El repositorio incluye el conjunto de modelado, los resultados de prueba de los seis modelos y los modelos tabulares, de modo que la exploración, la comparación y la predicción con los modelos tabulares funcionan al clonarlo. Los pesos de las redes y las fotografías ocupan demasiado para el repositorio y se obtienen de la carpeta compartida del equipo. Sin ellos, la aplicación marca las redes como «Sin artefacto» y avisa que la fotografía del registro no está disponible.

8. Conclusiones

Obtención y preparación de los datos. El objetivo se cumplió con un flujo reproducible. La descarga, la verificación y la extracción de atributos se ejecutan con una orden cada una y pueden reanudarse si se interrumpen. Las 26 068 fotografías de entrenamiento coinciden uno a uno con los registros de `Train.csv`. Después de la limpieza quedan 23 350 registros aptos para modelado, de los cuales 4 489 tienen diagnóstico de sequía. La partición agrupa por campo y usa una semilla fija. Así ningún campo aparece a ambos lados de la evaluación, y todo el equipo trabaja con la misma partición.

Análisis de los datos. El análisis exploratorio mostró tres características que condicionan el modelado:

- Solo el 19 % de las fotografías aptas tiene diagnóstico de sequía, y únicamente esas tienen una magnitud distinta de cero.
- Las fotografías se agrupan por campo: en una partición aleatoria, casi nueve de cada diez registros de validación pertenecerían a campos ya vistos.
- Las condiciones de captura varían entre temporadas, sobre todo en SR2021, que mezcla fotografías de baja y de alta resolución.

Por eso los modelos se entrenaron solo con fotografías DR, la partición separa campos y el informe distingue entre el alcance DR y el global.

Construcción y comparación de modelos. Se entrenaron y evaluaron seis modelos sobre la misma partición. Los cinco que aprenden de los datos superan al predictor constante, cuyo RMSE DR es de 24.09:

- Los modelos sobre atributos globales mejoran poco. La regresión sobre exceso de verde llega a 21.44 y el Random Forest, a 20.61, con R^2 de 0.21 y 0.27.
- Las redes convolucionales mejoran más. DenseNet121 llega a 19.36; la ResNet50, a 18.33, y la ResNet50 ajustada, a 17.84. Explican del 35 % al 45 % de la varianza de la magnitud.
- Con el mismo procedimiento, la ResNet50 supera a DenseNet121 por un punto de RMSE, una diferencia significativa según el bootstrap pareado.
- Todos los modelos mejoran a la referencia en las cuatro temporadas, y su error de prueba es cercano al de validación, señal de que la evaluación por campo es confiable.
- Todos comprimen las predicciones hacia el centro de la escala. Las redes ordenan bien las fotografías por severidad, pero sobrestiman los daños leves y subestiman los severos. Con un error típico de 13 a 19 puntos, su estimación es útil para priorizar reclamos y apoyar al evaluador, no para reemplazarlo en el cálculo final del monto.

El contraste entre familias responde al problema científico: aprender la representación de la fotografía reduce el error casi tres puntos de RMSE respecto del mejor modelo sobre atributos. El exceso de verde resume buena parte de la señal de color, y concentra casi la mitad de la importancia del Random Forest, pero la textura y la estructura de la escena aportan información que los promedios no capturan.

Ajuste de hiperparámetros y de la receta. Los hiperparámetros se eligieron con validación agrupada por campo, y cada configuración probada quedó registrada con su error de validación. En los tres algoritmos con búsqueda, el error dependió poco de la configuración. Las 30 combinaciones del Random Forest quedaron a 0.4 puntos de RMSE entre sí, y las cuatro configuraciones de la ResNet50, a menos de un punto. En DenseNet121, la diferencia llegó a dos puntos porque ajustar su último bloque con la tasa mayor sobreajustó desde la segunda época.

La receta combinada de la ResNet50 ajustada sí mejoró de forma consistente. Consiste en ajustar toda la red con tasas por capa y programa coseno, y en usar una entrada de 320 y el promedio con el reflejo de la imagen. En los pliegues de validación redujo el RMSE de 19.58 a 17.91. En la prueba redujo el MAE de 14.61 a 13.50, una diferencia significativa, y el RMSE de 18.33 a 17.84.

El cambio individual más útil fue la resolución de entrada. Una explicación probable es que, al reducir menos las fotografías, se conservan detalles de las hojas que la entrada de 224 pierde. Una lección práctica es evaluar en varios pliegues con una política fija: en un solo pliegue y eligiendo la mejor época, las diferencias de menos de un punto se confunden con ruido.

Las mejoras siguientes más prometedoras están en los datos y no en la arquitectura:

- Más fotografías de daños severos.
- Ponderar los niveles poco frecuentes.
- Tratar la magnitud como una variable ordinal de diez niveles.

Costo computacional. Los seis modelos se entrenaron en la misma laptop. Los modelos sobre atributos se entrenan en segundos en la CPU y predicen en centésimas de milisegundo. Las redes tardaron de 10 a 17 minutos en una GPU de laptop y predicen en 20 a 31 ms por fotografía. Todas pueden entrenarse y servirse en hardware de consumo y responder en línea desde la aplicación.

La elección del modelo depende de la prioridad. El criterio del proyecto prefiere el más rápido cuando el RMSE difiere en menos de un punto, y recomienda la ResNet50. Si la latencia no es una restricción, la ajustada ofrece el menor error. Si no hay GPU y se necesita una respuesta instantánea, el Random Forest es una alternativa con un error 2.3 puntos mayor que la ResNet50.

Aplicación. La API y la interfaz web permiten consultar los datos, comparar los modelos y estimar la magnitud de una fotografía nueva con uno o con todos los modelos. Cada modelo entrenado aparece en la aplicación sin cambios en el contrato, porque cumple la interfaz común de `ModeloMagnitud`.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

CGIAR. (2021, 19 de enero). *ACRE Africa and IFPRI receive award from Lacuna Fund to develop unique agricultural datasets through smartphones*. https://www.cgiar.org/news-events/news/acre-africa-and-ifpri-receive-award-from-lacuna-fund-to-develop-unique-agricultural-datasets-through-smartphones

Chandel, N. S., Chakraborty, S. K., Rajwade, Y. A., Dubey, K., Tiwari, M. K., & Jat, D. (2021). Identifying crop water stress using deep learning models. *Neural Computing and Applications, 33*, 5353–5367. https://doi.org/10.1007/s00521-020-05325-4

Chandel, N. S., Rajwade, Y. A., Dubey, K., Chandel, A. K., Subeesh, A., & Tiwari, M. K. (2022). Water stress identification of winter wheat crop with state-of-the-art AI techniques and high-resolution thermal-RGB imagery. *Plants, 11*(23), Article 3344. https://doi.org/10.3390/plants11233344

Cho, S. B., Soleh, H. M., Choi, J. W., Hwang, W.-H., Lee, H., Cho, Y.-S., Cho, B.-K., Kim, M. S., Baek, I., & Kim, G. (2024). Recent methods for evaluating crop water stress using AI techniques: A review. *Sensors, 24*(19), Article 6313. https://doi.org/10.3390/s24196313

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *2009 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 248–255). IEEE. https://doi.org/10.1109/CVPR.2009.5206848

Food and Agriculture Organization of the United Nations. (s. f.). *Assessing and measuring your crop*. https://www.fao.org/4/x8234e/x8234e06.htm

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En *2016 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). IEEE. https://doi.org/10.1109/CVPR.2016.90

Huang, G., Liu, Z., van der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. En *2017 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2261–2269). IEEE. https://doi.org/10.1109/CVPR.2017.243

Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture, 147*, 70–90. https://doi.org/10.1016/j.compag.2018.02.016

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature, 521*(7553), 436–444. https://doi.org/10.1038/nature14539

Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science, 7*, Article 1419. https://doi.org/10.3389/fpls.2016.01419

Patra, A. K., & Sahoo, L. (2024). Explainable light-weight deep learning pipeline for improved drought stress identification. *Frontiers in Plant Science, 15*, Article 1476130. https://doi.org/10.3389/fpls.2024.1476130

Waithaka, L., Kramer, B., Hufkens, K., Kivuva, B., & Mansabdar, S. (2022). *Eyes on the Ground image data* (Versión 1.0) [Conjunto de datos]. Radiant MLHub. https://doi.org/10.34911/rdnt.1bs2jw

Woebbecke, D. M., Meyer, G. E., Von Bargen, K., & Mortensen, D. A. (1995). Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE, 38*(1), 259–269. https://doi.org/10.13031/2013.27838

Zindi. (2023). *CGIAR Eyes on the Ground Challenge*. https://zindi.world/competitions/cgiar-eyes-on-the-ground-challenge