Ojos en el campo
Daño por sequía en cultivos

PROYECTO 2 · CGIAR EYES ON THE GROUND

¿Cuánta cosecha se llevó la sequía? Estimarlo desde una foto

Comparamos seis modelos de aprendizaje automático para estimar la magnitud del daño por sequía en fotografías de pequeños productores de Kenia.

Ernesto Ascencio · Hugo Barillas · Esteban Cárcamo · Diego López

CC3084 Data Science · Sección 20 · 19 de octubre de 2026



Magnitud 100 · Sequía

Foto de prueba de SR2021: el suelo queda expuesto y la planta, seca.

01 · EL PROBLEMA

Cada reclamo espera a que alguien mire la foto

ACRE Africa revisa a mano las fotos que envían los productores para estimar la pérdida. Esa revisión retrasa los pagos.

26 068
fotografías de entrenamiento con diagnóstico y magnitud del daño

17 %
tiene diagnóstico de sequía; solo esas tienen pérdida mayor que cero

0 – 100
escala de la magnitud del daño, en pasos de 10 puntos

Pregunta del proyecto: ¿con qué error se estima la magnitud del daño por sequía desde una foto, cuando el modelo se evalúa en campos que nunca vio?

02 · LOS DATOS

Tres hallazgos de los datos definieron el modelado

Lo que encontramos en las 26 068 fotos antes de entrenar cualquier modelo.

1

Solo la sequía tiene magnitud

Los otros siete diagnósticos valen siempre 0, así que estimamos la severidad solo dentro de la sequía.

2

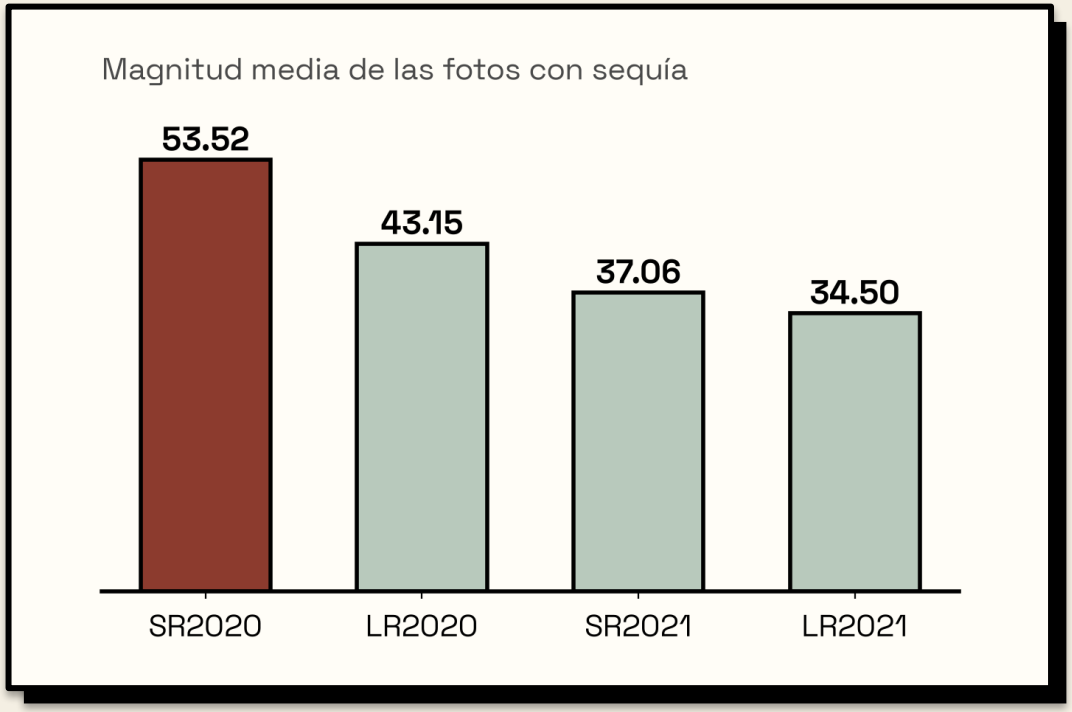
87.9 %

de una validación aleatoria cae en campos que ya estaban en el entrenamiento: hay que separar por campo.

3

37.6 %

de las fotos de SR2021 supera 5 megapíxeles; en LR2020 y SR2020 todas medían 640 × 480.



03 · CÓMO EVALUAMOS

Evaluamos en campos que ningún modelo vio

Partición agrupada por campo, con la misma semilla para todo el equipo.

23 350
fotos aptas de 3 051 campos

→

4 489
con diagnóstico de sequía

→

Entrenamiento
3 655 fotos · 1 453 campos

Prueba
834 fotos · 358 campos

Separación por campo
El 20 % de los campos va a prueba con semilla fija. Ningún campo aparece en ambos lados.

Regla fija: otros diagnósticos → magnitud 0
Los modelos solo aprenden la severidad de la sequía.

Métricas: MAE · RMSE · R^2
Sobre las 834 fotos con sequía de prueba, usadas una sola vez.

04 · SEIS MODELOS

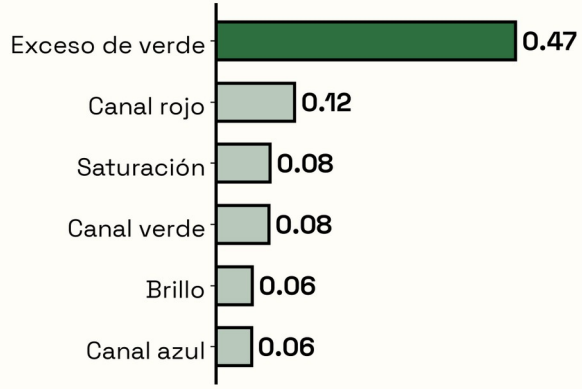
El color explica parte del daño, pero no todo

Tres familias de modelos; los de atributos solo ven promedios de color y exposición de la foto.

Referencia
Predictor constante y regresión sobre el exceso de verde

Atributos
Random Forest con 9 atributos de color y exposición de la foto

Redes convolucionales
ResNet50, ResNet50 ajustada y DenseNet121, preentrenadas en ImageNet



20.61
RMSE del Random Forest

24.09
RMSE del predictor constante

05 · RESNET50

Ajustar toda la red y ver la foto a 320 px bajó el error

Dos versiones de la misma arquitectura: el procedimiento común y una receta ajustada.

18.33
RMSE de la ResNet50 con el procedimiento común

17.84
RMSE de la ResNet50 ajustada, el menor de los seis

−1.11
puntos de MAE de la ajustada; mejora significativa por bootstrap

Receta ajustada
Toda la red con tasas por capa · programa coseno de 10 épocas · entrada de 320 px · promedio con la imagen reflejada

El cambio que más ayudó
320 px: 17.43 de RMSE en validación
224 px: 18.39

06 · DENSENET121

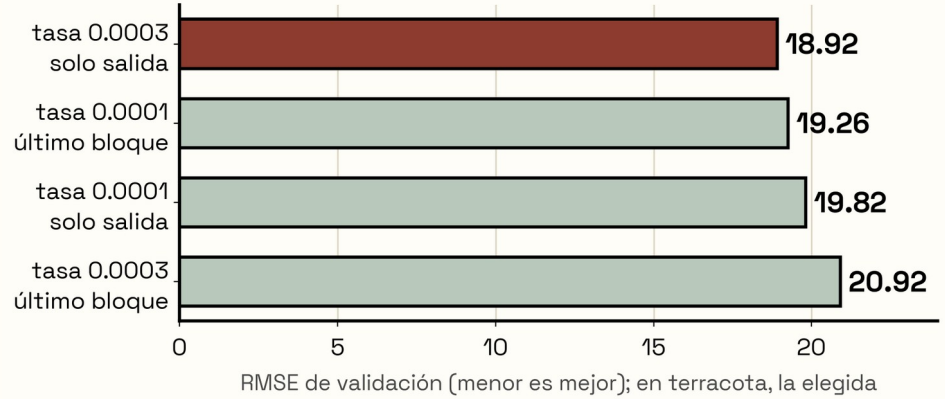
DenseNet121 quedó un punto detrás de ResNet50

Mismo procedimiento que la ResNet50, para que la diferencia refleje solo la arquitectura.

19.36
RMSE de DenseNet121 en la prueba

8 M
parámetros; ResNet50 tiene 25.6 M

+1.02
puntos de RMSE frente a ResNet50, diferencia significativa (IC 95 %: 0.38 a 1.65)

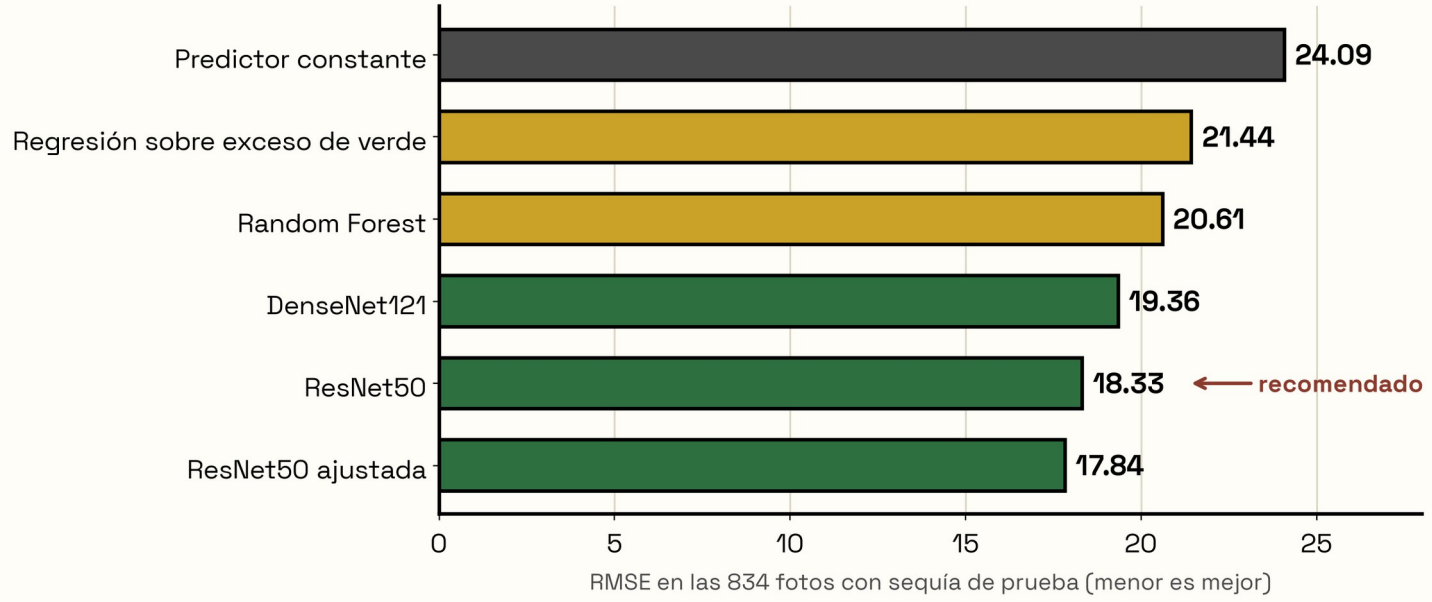


Mejor configuración: solo la capa de salida, tasa 3×10^{-4}, 14 épocas. Al ajustar el último bloque denso, sobreajustó desde la época 2.

07 · COMPARACIÓN

Las redes bajan hasta 26 % el error de referencia

RMSE sobre las 834 fotos con sequía de prueba: menor es mejor.



−26 %
RMSE de la ajustada frente al constante

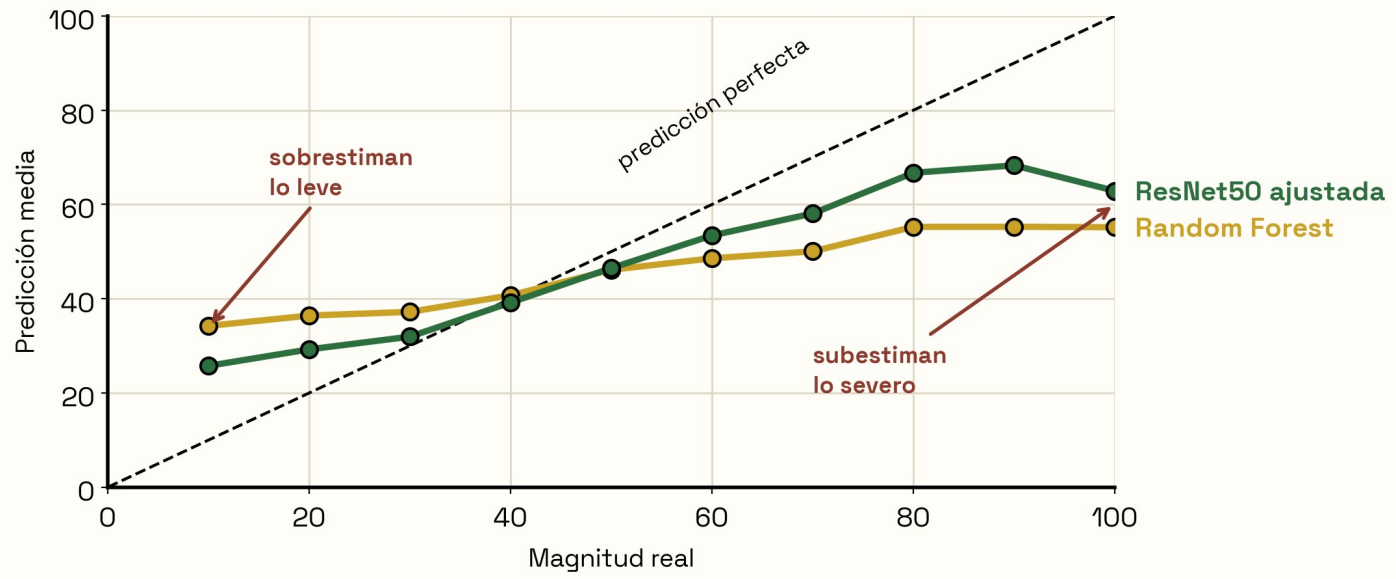
Validación ≈ prueba
ResNet50: 17.99 en validación y 18.33 en prueba.

SR2020, la temporada más difícil
Todos los modelos fallan más ahí.

08 · LIMITACIÓN

Ordenan la severidad, pero comprimen los extremos

Predicción media por nivel de magnitud real de la ResNet50 ajustada y del Random Forest.



77 %
a 20 puntos o menos del valor real

48 %
a 10 puntos o menos del valor real

Sirve para priorizar reclamos y apoyar al evaluador, no para fijar el monto final.

09 · LA APLICACIÓN

Una app para explorar, comparar y estimar

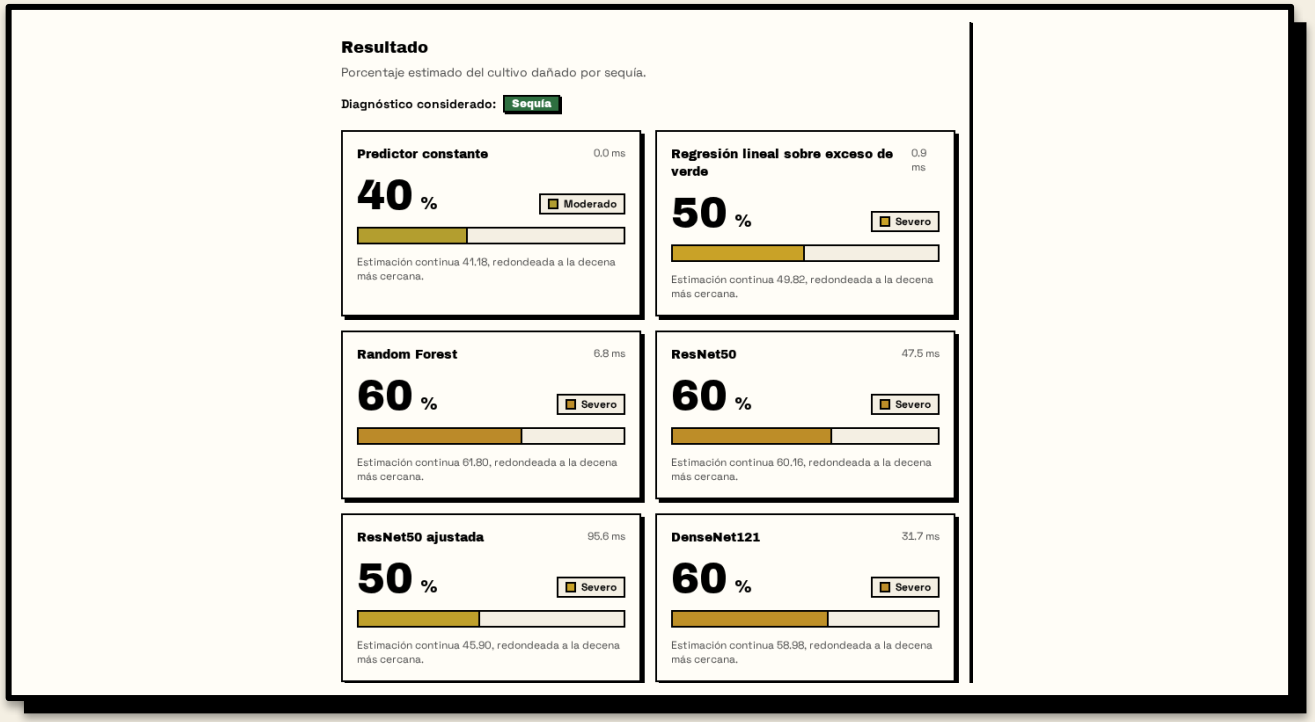
React y FastAPI con un contrato OpenAPI compartido; muestra los datos y resultados reales.

Explorar distribuciones, correlaciones y cada registro con su foto

Modelos hiperparámetros, búsqueda y curva de entrenamiento

Rendimiento métricas, real contra predicho y error por grupo

Predecir sube una foto y compara la magnitud de cada modelo



10 · CONCLUSIONES

Recomendamos ResNet50 para la aplicación

Tres ideas que deja el proyecto.

1

Aprender de la foto supera al color

La mejor red baja 2.8 puntos el RMSE del Random Forest: la textura y la escena aportan información que los promedios no capturan.

2

ResNet50 para la app

18.33 de RMSE y 20 ms por foto. La ajustada mejora solo 0.5 puntos de RMSE y tarda 31 ms; se prefiere si la latencia no importa.

3

Siguiente paso: los datos

Más fotos de daño severo, ponderar los niveles poco frecuentes y tratar la magnitud como variable ordinal.



Ojos en el campo

Gracias. ¿Preguntas?

Ernesto Ascencio · Hugo Barillas · Esteban Cárcamo · Diego López

Repositorio

github.com/BARHUGO/CC3084-Proyecto2

Datos: CGIAR Eyes on the Ground, Zindi (2023)